

Proyecto Antigravity: Documentación Técnica

Tu Nombre

2026-04-23

Índice General

Introducción	5
Resumen Ejecutivo	5
1 Arquitectura del Sistema	6
1.1 Diagrama de Bloques	6
1.2 Modelado Matemático	6
2 Funcionalidades Detalladas	7
2.1 Algoritmos de AntigraVity	7
3 Especificaciones de Hardware	8
3.1 Tabla Comparativa Extensa	9
4 Capítulo VII: Analítica Predictiva y Machine Learning	10
4.1 7.1 Fundamentación Técnica y Selección de Modelos	10
4.1.1 7.1.1 Definición del Problema en Contexto Fast Food	10
4.1.2 7.1.2 Algoritmos Seleccionados	11
4.1.3 7.1.3 Métricas de Evaluación y Validación	12
4.2 7.2 Ingeniería de Características en la Capa de Transformación (dbt)	12
4.2.1 7.2.1 Modelado de Features en Snowflake	12
4.2.2 7.2.2 Tablas Maestras de Entrenamiento (OBTs)	13
4.2.3 7.2.3 Automatización del Pipeline de Limpieza	14
4.3 7.3 Desarrollo del Motor de Inferencia	14
4.3.1 7.3.1 Arquitectura del Servicio de Predicción	14
4.3.2 7.3.2 Implementación del Script de Entrenamiento	15
4.3.3 7.3.3 Gestión de Modelos y Serialización	16
4.3.4 7.3.4 Lógica de Fallback y Heurísticas de Negocio	16
4.4 7.4 Integración en el Frontend	17
4.4.1 7.4.1 Visualización de Resultados Predictivos	17
4.4.2 7.4.2 Diseño de Componentes para Toma de Decisiones en Tiempo Real	17
4.5 7.5 Estrategia de Despliegue y MLOps	18
4.5.1 7.5.1 Ciclo de Vida del Modelo	18
4.5.2 7.5.2 Monitoreo de Data Drift y Performance	18
5 Capítulo VIII: Análisis de Series de Tiempo y Pronósticos	20
5.1 8.1 Base Teórica de Series Temporales en el Negocio	20
5.1.1 8.1.1 Conceptos de Estacionalidad, Tendencia y Ciclo en Ventas de Fast Food	20
5.1.2 8.1.2 Modelos Estadísticos y Modernos	21
5.1.3 8.1.3 Manejo de Eventos Especiales y Feriados en Bolivia	22
5.2 8.2 Preparación y Agregación Temporal (dbt)	22
5.2.1 8.2.1 Modelado de Series de Tiempo: Granularidades	22
5.2.2 8.2.2 Técnicas de Lagging y Ventanas Móviles	23

5.2.3	8.2.3 Calidad de Datos Temporales	24
5.3	8.3 Lógica del Simulador y Motor de Proyecciones	25
5.3.1	8.3.1 Arquitectura del Simulador de Escenarios	25
5.3.2	8.3.2 Pronóstico Recursivo a 180 Días	25
5.3.3	8.3.3 Fórmulas de Impacto What-If	26
5.3.4	8.3.4 Integración con Cache para Alta Disponibilidad	27
5.4	8.4 Dashboards de Proyección y Simulación	27
5.4.1	8.4.1 Gráficos de Pronóstico con Intervalos de Confianza	27
5.4.2	8.4.2 Simulador Interactivo CBBA	28
5.5	8.5 Validación y Precisión de las Proyecciones	28
5.5.1	8.5.1 Backtesting de Modelos Temporales	28
5.5.2	8.5.2 Comparativa Real vs. Proyectado	29
6	Capítulo IX: Modelado Econométrico y Estratégico	30
6.1	9.1 Fundamentos de Econometría Aplicada: Caso 1 - Eficiencia Operativa (SFA)	30
6.1.1	9.1.1 Función de Producción Cobb-Douglas para Puntos de Venta	30
6.1.2	9.1.2 Análisis de Frontera Estocástica (SFA) para la Medición de Eficiencia	31
6.1.3	9.1.3 Definición de Insumos (Inputs) y Resultados (Outputs) Económicos	31
6.2	9.2 Implementación de Lógica Económica en dbt	31
6.2.1	9.2.1 Cálculo de Indicadores de Productividad Marginal	31
6.2.2	9.2.2 Integración de Datos de Costos, Merma y Recursos Humanos	32
6.2.3	9.2.3 Normalización de Variables para Modelos Estadísticos	32
6.3	9.3 Motor de Análisis Estadístico (Backend & ML)	32
6.3.1	9.3.1 Procesamiento de Optimización de Recursos y SFA	32
6.3.2	9.3.2 Desarrollo de Controladores para Análisis de Eficiencia	33
6.3.3	9.3.3 Generación de Insights Prescriptivos	33
6.4	9.4 Caso 2 - Optimizador de Margen e Inferencia de Elasticidad-Precio	33
6.4.1	9.4.1 Modelo Log-Log de Elasticidad	34
6.4.2	9.4.2 Implementación del Optimizador de Margen	34
6.5	9.5 Dashboard de Inteligencia Estratégica (Frontend)	34
6.5.1	9.5.1 Visualización de la Frontera de Eficiencia por Sucursal	34
6.5.2	9.5.2 Mapas de Calor y Rankings de Desempeño Operativo-Económico	34
6.6	9.6 Despliegue y Aplicación en la Toma de Decisiones	35
6.6.1	9.6.1 Auditoría de Resultados Económicos	35
6.6.2	9.6.2 Impacto de las Recomendaciones Econométricas en el ROI del Proyecto	35

List of Figures

1	Logo del Proyecto	5
2.1	Flujo de trabajo	7

List of Tables

Introducción

Bienvenido a la documentación técnica oficial del sistema desarrollado bajo el framework Antigraity. Este documento detalla la arquitectura, funcionalidades y especificaciones matemáticas del proyecto.

Resumen Ejecutivo

Este manual consta de 150 páginas detallando cada módulo del sistema.



Figure 1: Logo del Proyecto

Chapter 1

Arquitectura del Sistema

En este capítulo analizamos el núcleo del sistema.

1.1 Diagrama de Bloques

La estructura principal se basa en la eficiencia de datos.

Componente	Función	Latencia
Core	Lógica	10ms
DB	Almacén	50ms

1.2 Modelado Matemático

La eficiencia del sistema se define por la siguiente fórmula:

$$f(x) = \int_{-\infty}^{\infty} e^{-x^2} dx$$

Chapter 2

Funcionalidades Detalladas

Aquí se describen las capacidades operativas.

2.1 Algoritmos de Antigravity

El sistema utiliza agentes inteligentes para la autodocumentación.

“La automatización es la clave de la escala.”

Como se observa en la [Figure 2.1](#), el proceso es lineal.




Figure 2.1: Flujo de trabajo

Chapter 3

Especificaciones de Hardware

A continuación, se presenta una tabla detallada que requiere orientación horizontal.

3.1 Tabla Comparativa Extensa

Modelo	CPU	RAM	Almacenamiento	Ancho de Banda	GPU	Refrigeración
v1.0	8c	16GB	512GB	1Gbps	4GB	Aire
v2.0	16c	64GB	2TB	10Gbps	12GB	Líquida
v3.0	32c	128GB	5TB	40Gbps	24GB	Nitrógeno

Chapter 4

Capítulo VII: Analítica Predictiva y Machine Learning

El presente capítulo describe en detalle el diseño, desarrollo e implementación del módulo de analítica predictiva del sistema HGC. Este módulo constituye el núcleo de inteligencia artificial del proyecto, permitiendo a la organización anticipar comportamientos de clientes, clasificar productos, proyectar rentabilidad de sucursales y detectar patrones de canibalización interna. La arquitectura adoptada sigue un enfoque MLOps completo, donde cada modelo transita por fases de experimentación, entrenamiento, registro, despliegue y monitoreo continuo.

4.1 7.1 Fundamentación Técnica y Selección de Modelos

4.1.1 7.1.1 Definición del Problema en Contexto Fast Food

El negocio de comida rápida en Bolivia presenta características particulares que condicionan la elección de estrategias predictivas. A diferencia de mercados maduros con abundancia de datos estructurados, el contexto local combina alta rotación de clientes jóvenes, variabilidad estacional marcada por feriados nacionales (Carnaval, Día de la Madre, Fiestas de San Juan), y una distribución geográfica concentrada en Cochabamba con expansión hacia Santa Cruz y La Paz.

El sistema HGC implementa cinco módulos predictivos diferenciados según la naturaleza del problema:

Módulo	Tipo de Problema	Variable Objetivo	Algoritmo Principal
Churn Prediction	Clasificación Binaria	TARGET_ES_CHURN (0/1)	Random Forest / XGBoost
CLV Prediction	Regresión Continua	Valor de Vida del Cliente (Bs)	Gradient Boosting
BCG Clustering	Clustering	Cuadrante BCG	K-Means + Reglas de Negocio
Cannibalization	Clasificación Multiclase	Nivel de Canibalización	XGBoost Multiclass
Branch Performance	Regresión Continua	Beneficio Neto Proyectado (Bs)	Gradient Boosting

La distinción entre problemas de regresión y clasificación no es trivial: un error en la selección del tipo de modelo puede conducir a predicciones sin sentido semántico. Por ejemplo, predecir la probabilidad de churn como un valor continuo sin umbral de decisión dificultaría la acción operativa. Por ello, el módulo Churn retorna un valor binario con lógica de fallback calibrada.

4.1.2 7.1.2 Algoritmos Seleccionados

El proceso de selección de algoritmos siguió una metodología de experimentación comparativa bajo MLflow. Para el módulo Churn, se evaluaron cuatro familias de modelos:

Regresión Logística actúa como línea base interpretable. Su formulación matemática es:

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4)}}$$

Donde x_1 = frecuencia histórica, x_2 = monto gastado, x_3 = recencia en días, x_4 = codificación del rango etario.

Random Forest con 100 árboles y profundidad máxima de 8 niveles. La predicción final se obtiene por votación mayoritaria:

$$\hat{y} = \text{mode}\{h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_{100}(\mathbf{x})\}$$

Cada árbol h_t se entrena sobre un subconjunto aleatorio de observaciones (bootstrap) y características (feature bagging). La profundidad máxima de 8 previene el sobreajuste dado el tamaño moderado del dataset de entrenamiento.

XGBoost implementa Gradient Boosting con regularización L1/L2. La función objetivo optimizada es:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2$$

Donde T es el número de hojas, $\mathbf{w}$ el vector de pesos foliares, γ el umbral mínimo de ganancia y λ el término de regularización L2.

Red Neuronal (MLPClassifier) con arquitectura (64, 32): dos capas ocultas con 64 y 32 neuronas respectivamente, función de activación ReLU y optimizador Adam con hasta 300 épocas de entrenamiento.

La arquitectura del pipeline de preprocesamiento unifica el tratamiento de variables:

```
preprocessor = ColumnTransformer(  
    transformers=[  
        ('num', StandardScaler(),  
         ['FEATURE_FRECUECIA_HISTORICA',  
          'FEATURE_MONTO_GASTO_HISTORICO',  
          'FEATURE_RECENCIA_DIAS']),  
        ('cat', OneHotEncoder(handle_unknown='ignore'),  
         ['RANGO_EDAD'])  
    ]  
)
```

El **StandardScaler** normaliza las variables numéricas a media cero y varianza unitaria, esencial para la convergencia del MLP. El **OneHotEncoder** transforma el rango etario en variables indicadoras binarias, manteniendo compatibilidad con todos los algoritmos del portafolio.

4.1.3 7.1.3 Métricas de Evaluación y Validación

La evaluación de modelos de clasificación para churn emplea múltiples métricas complementarias, dado que la precisión global (accuracy) puede ser engañosa ante desbalance de clases:

Métrica	Fórmula	Interpretación en Churn
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$	% total correctamente clasificado
Precisión	$\frac{TP}{TP+FP}$	De los predichos como churn, cuántos lo son
Recall	$\frac{TP}{TP+FN}$	De los que sí hacen churn, cuántos detectamos
F1-Score	$\frac{2 \cdot P \cdot R}{P+R}$	Balance entre precisión y recall
AUC-ROC	$\int_0^1 TPR(FPR) dFPR$	Capacidad discriminante global

Para los modelos de regresión (CLV, Branch Performance) se emplean:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

La partición de datos sigue la proporción 80/20 con semilla aleatoria fija (`random_state=42`) para garantizar reproducibilidad de resultados entre ejecuciones del pipeline:

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

4.2 7.2 Ingeniería de Características en la Capa de Transformación (dbt)

4.2.1 7.2.1 Modelado de Features en Snowflake

La ingeniería de características es, junto con la calidad de los datos de entrada, el factor más determinante en el rendimiento de cualquier modelo predictivo. En el sistema HGC, esta capa es gestionada íntegramente por dbt (Data Build Tool), que transforma los datos brutos almacenados en las capas Staging e Intermediate de Snowflake en tablas de features materializadas y optimizadas para consumo por los scripts de entrenamiento.

La arquitectura de capas del data warehouse es la siguiente:

```
RAW (Snowflake Stage)
  STAGING (dbt: limpieza y tipado)
    INTERMEDIATE (dbt: enriquecimiento)
      ML/FEATURES (dbt: ingeniería de características)
        TRAINING_DATASETS (dbt: OBTs para entrenamiento)
          GOLD (dbt: marts para consumo)
```

El modelo `feat_clientes_comportamiento.sql` es el artefacto central para los módulos Churn y CLV. Consolida en una única tabla desnormalizada toda la información conductual del cliente:

```

{{ config(materialized='table') }}

with clientes as (
    select * from {{ ref('int_clientes_enriquecidos') }}
),
dim_cliente as (
    select id_cliente_sk, id_cliente_nk
    from {{ ref('dim_cliente') }}
),
ventas as (
    select
        dc.id_cliente_nk,
        sum(v.cantidad_vendida) as cantidad_articulos_comprados,
        count(distinct v.nro_pedido_dd) as frecuencia_pedidos,
        sum(v.monto_subtotal_netto) as valor_monetario_total,
        avg(v.monto_subtotal_netto) as ticket_promedio,
        max(to_date(cast(v.id_fecha_sk as varchar), 'YYYYMMDD'))
            as fecha_ultima_compra,
        min(to_date(cast(v.id_fecha_sk as varchar), 'YYYYMMDD'))
            as fecha_primera_compra
    from {{ ref('fact_ventas_detalle') }} v
    join dim_cliente dc on v.id_cliente_sk = dc.id_cliente_sk
    group by 1
)
select
    c.id_cliente_nk,
    c.rango_edad,
    coalesce(v.frecuencia_pedidos, 0) as frecuencia_pedidos,
    coalesce(v.valor_monetario_total, 0) as valor_monetario_total,
    case
        when v.fecha_ultima_compra is not null
        then datediff(day, v.fecha_ultima_compra, current_date())
        else 9999
    end as recencia_dias,
    case
        when v.fecha_primera_compra is not null
        then datediff(day, v.fecha_primera_compra, current_date())
        else 0
    end as antiguedad_dias
from clientes c
left join ventas v on c.id_cliente_nk = v.id_cliente_nk

```

Este modelo implementa el patrón RFM (Recency, Frequency, Monetary) ampliamente utilizado en marketing cuantitativo. La lógica de DATEDIFF garantiza que la recencia siempre esté expresada en días calendarios desde la última compra hasta la fecha de ejecución del pipeline, manteniendo la frescura del feature sin necesidad de re-entrenamiento inmediato.

4.2.2 7.2.2 Tablas Maestras de Entrenamiento (OBTs)

Los datos de features se consolidan en One Big Tables (OBTs) dentro del schema `TRAINING_DATASETS` de Snowflake. Esta estrategia de desnormalización total minimiza los JOINS en tiempo de entrenamiento y garantiza que el script Python reciba exactamente las columnas necesarias sin procesamiento adicional:

Tabla OBT	Filas Aprox.	Features	Target
OBT_CHURN_PREDICTION	15,000+	4	TARGET_ES_CHURN
OBT_CLV_PREDICTION	15,000+	4	TARGET_CLV_VALOR
OBT_BCG_CLUSTERING	500+	3	(sin supervisión)
OBT_BRANCH_PERFORMANCE	200+	8	TARGET_BENEFICIO_NETO

La tabla OBT_CHURN_PREDICTION expone exactamente las columnas que el pipeline de entrenamiento consume:

- RANGO_EDAD: variable categórica ordinal con valores 18-25, 26-35, 36-45, 46-60, +60
- FEATURE_FRECUENCIA_HISTORICA: número entero de pedidos realizados en toda la historia del cliente
- FEATURE_MONTO_GASTO_HISTORICO: suma acumulada en bolivianos de todos los pedidos
- FEATURE_RECENCIA_DIAS: días transcurridos desde la última compra (999 si nunca compró)
- TARGET_ES_CHURN: etiqueta binaria (1 = cliente perdido, 0 = cliente activo)

4.2.3 7.2.3 Automatización del Pipeline de Limpieza

El pipeline dbt incorpora múltiples capas de defensiva de calidad de datos. Los valores nulos en features numéricos son tratados con estrategias diferenciadas según el significado semántico de cada variable:

```
-- En el script de entrenamiento (Python), segunda línea de defensa:
X['FEATURE_FRECUENCIA_HISTORICA'] = X['FEATURE_FRECUENCIA_HISTORICA'].fillna(0)
X['FEATURE_MONTO_GASTO_HISTORICO'] = X['FEATURE_MONTO_GASTO_HISTORICO'].fillna(0)
X['FEATURE_RECENCIA_DIAS'] = X['FEATURE_RECENCIA_DIAS'].fillna(9999)
X['RANGO_EDAD'] = X['RANGO_EDAD'].fillna('Desconocido')
```

La asignación de 9999 como recencia para clientes sin historial de compra codifica semánticamente la ausencia de comportamiento como máxima distancia temporal, lo cual es coherente con la definición de churn: un cliente que nunca compró tiene la máxima probabilidad de “abandono” desde una perspectiva de negocio.

El flujo completo de automatización ejecuta en este orden:

1. **dbt run --select staging:** Normaliza y tipifica datos fuente
2. **dbt run --select intermediate:** Enriquece con dimensiones y calcula métricas intermedias
3. **dbt run --select ml.features:** Materializa los feature stores como tablas físicas en Snowflake
4. **dbt run --select ml.datasets:** Genera las OBTs de entrenamiento
5. **python train.py:** Consume OBTs y entrena modelos, registrando en MLflow
6. **mlflow models serve:** Expone endpoints de inferencia

4.3 7.3 Desarrollo del Motor de Inferencia

4.3.1 7.3.1 Arquitectura del Servicio de Predicción

El sistema de predicción adopta una arquitectura de doble ruta (dual-path) que garantiza disponibilidad del servicio independientemente del estado del servidor MLflow:

Solicitud REST (Frontend Next.js)

Node.js API Gateway (hgc-back, puerto 3001)

[Ruta 1] MLflow Server disponible

POST http://127.0.0.1:5001/invocations

(timeout: 2000ms)

[Ruta 2] Fallback Heurístico (MLflow no disponible)

Lógica de reglas calibradas en código

Esta arquitectura garantiza que el dashboard nunca presente una pantalla de error al usuario final. El fallback heurístico, aunque menos preciso que el modelo entrenado, produce resultados semánticamente coherentes y calibrados con el comportamiento real de los clientes bolivianos.

4.3.2 7.3.2 Implementación del Script de Entrenamiento

El script `train.py` del módulo Churn implementa un ciclo de experimentación MLOps completo:

```
mlflow.set_tracking_uri("sqlite:///mlflow.db")
mlflow.set_experiment("HGC_Churn_Prediction")

models = {
    "LogisticRegression": LogisticRegression(random_state=42),
    "RandomForest": RandomForestClassifier(
        n_estimators=100, max_depth=8, random_state=42),
    "XGBoost": XGBClassifier(
        use_label_encoder=False,
        eval_metric='logloss',
        random_state=42),
    "NeuralNetwork": MLPClassifier(
        hidden_layer_sizes=(64, 32),
        max_iter=300,
        random_state=42)
}

best_accuracy = 0
best_pipeline = None

for model_name, model in models.items():
    with mlflow.start_run(run_name=model_name):
        pipeline = Pipeline(steps=[
            ('preprocessor', preprocessor),
            ('classifier', model)
        ])
        pipeline.fit(X_train, y_train)
        y_pred = pipeline.predict(X_test)
        acc = accuracy_score(y_test, y_pred)

        mlflow.log_param("model_type", model_name)
        mlflow.log_metric("accuracy", acc)

        if acc > best_accuracy:
            best_accuracy = acc
            best_pipeline = pipeline
```

El modelo ganador se registra automáticamente en el Model Registry de MLflow bajo el nombre `HGC_Churn_Model_Pro`, lo que habilita el versionado y el rollback a versiones previas en caso de degradación del rendimiento.

4.3.3 7.3.3 Gestión de Modelos y Serialización

MLflow serializa los pipelines de sklearn como artefactos estructurados bajo el formato `mlflow.sklearn`. La estructura de directorios generada es:

```
mlruns/
  [experiment_id]/
    [run_id]/
      artifacts/
        churn_model/
          MLmodel           (metadatos)
          model.pkl          (pipeline serializado)
          conda.yaml         (entorno reproducible)
          requirements.txt
        metrics/
          accuracy
```

El servidor de inferencia de MLflow expone el modelo via HTTP REST:

```
mlflow models serve \
  -m "models:/HGC_Churn_Model_Pro/Production" \
  -p 5001 \
  --no-conda
```

El payload de solicitud sigue el formato `dataframe_split`:

```
{
  "dataframe_split": {
    "columns": [
      "RANGO_EDAD",
      "FEATURE_FRECUENCIA_HISTORICA",
      "FEATURE_MONTO_GASTO_HISTORICO",
      "FEATURE_RECENCIA_DIAS"
    ],
    "data": [["26-35", 12, 850.50, 45]]
  }
}
```

La respuesta devuelve:

```
{
  "predictions": [0]
}
```

Donde 0 indica cliente sin riesgo de churn y 1 indica churn inminente.

4.3.4 7.3.4 Lógica de Fallback y Heurísticas de Negocio

Cuando MLflow no está disponible (timeout de 2 segundos), el controlador Node.js activa un sistema de scoring basado en reglas calibradas con conocimiento de dominio del negocio HGC:

```
let riskScore = 0;
// Recencia: mayor peso (hasta 50 puntos)
riskScore += Math.min(50, (recenciaNum / 180) * 50);
// Frecuencia: efecto protector (hasta -25 puntos)
riskScore -= Math.min(25, (freqNum / 30) * 25);
// Monto: efecto protector (hasta -15 puntos)
riskScore -= Math.min(15, (montoNum / 3000) * 15);
// Ajuste por segmento etario
```

```
if (edad === "18-25") riskScore += 10;
else if (edad === "+60" || edad === "46-60") riskScore -= 10;

isChurn = riskScore > 25;
```

Las heurísticas de negocio adicionales ajustan el resultado final según patrones observados en el contexto boliviano:

Segmento	Condición	Ajuste
Adultos mayores (+46)	Recencia 90 días Y monto > Bs500	Churn = false
Jóvenes (18-25)	Recencia > 45 días	Churn = true
General	MLflow disponible	Modelo entrenado

Este diseño refleja el conocimiento de que los clientes adultos de mayor poder adquisitivo en Bolivia son más leales y toleran períodos de inactividad más largos sin que esto indique abandono real.

4.4 7.4 Integración en el Frontend

4.4.1 7.4.1 Visualización de Resultados Predictivos

El dashboard de predicciones está desarrollado en Next.js 14 con TypeScript y recharts para la visualización. El componente `CustomerChurn.tsx` gestiona el estado de la predicción, el formulario de entrada y la visualización del resultado.

La arquitectura de componentes para el módulo de predicciones sigue el patrón:

```
/app/system/predictions/
  churn/
    CustomerChurn.tsx
  clv/
    CLVPrediction.tsx
  bcg/
    BCGPortfolio.tsx
  cannibalization/
    CannibalizationAnalysis.tsx
  branch-performance/
    BranchPerformance.tsx
```

Cada componente implementa:

1. **Formulario de entrada:** Controles deslizantes y selects para los parámetros del modelo
2. **Llamada API:** `fetch` al backend Express con manejo de errores
3. **Visualización de resultado:** Indicador visual codificado por color (rojo/verde para churn, gradiente para CLV)
4. **Ficha Técnica:** Panel colapsable que muestra métricas de validación del modelo (accuracy, F1, matriz de confusión)

4.4.2 7.4.2 Diseño de Componentes para Toma de Decisiones en Tiempo Real

La experiencia de usuario está diseñada para gerentes operativos sin formación técnica en estadística. El resultado de la predicción se presenta en lenguaje natural:

- **Churn = 1:** “ CLIENTE EN RIESGO – Se recomienda activar campaña de retención”
- **Churn = 0:** “ CLIENTE ACTIVO – Perfil de cliente leal”

Para el CLV, el valor monetario se presenta con formato boliviano (Bs X,XXX.XX) y se contextualiza en percentiles respecto al promedio del segmento etario correspondiente.

El componente de Rendimiento de Sucursal implementa cuatro categorías de estado con codificación visual:

Estado	Umbral Beneficio Neto	Color UI	Acción Recomendada
VIP (Expansión)	Bs 15,000,000	Ámbar	Evaluar apertura de sucursal adicional
Normal	Bs 8,000,000	Verde	Mantener operación actual
Alerta	Bs 3,000,000	Amarillo	Revisar eficiencia y costos
Operativa			
Riesgo	< Bs 3,000,000	Rojos	Intervención gerencial
Crítico			inmediata

4.5 7.5 Estrategia de Despliegue y MLOps

4.5.1 7.5.1 Ciclo de Vida del Modelo

El ciclo de vida de cada modelo en el sistema HGC comprende cinco etapas formales:

Etapas 1 – Desarrollo: El científico de datos experimenta con algoritmos y parámetros en notebooks Jupyter bajo el directorio `hgc-ml/notebooks/`. Cada experimento queda registrado automáticamente en MLflow con sus parámetros, métricas y artefactos.

Etapas 2 – Validación: El modelo candidato se evalúa contra el conjunto de test con las métricas de referencia. Se verifica que la mejora respecto al modelo en producción supere un umbral mínimo del 2% en accuracy (para clasificación) o 5% en RMSE (para regresión).

Etapas 3 – Registro: El modelo validado se registra en el MLflow Model Registry con un nombre estandarizado (`HGC_[Módulo]_Model_Pro`) y se asigna al stage **Staging**.

Etapas 4 – Producción: Tras aprobación manual del equipo técnico, el modelo pasa al stage **Production**. El servidor MLflow sirve automáticamente la versión de producción al recibir solicitudes de inferencia.

Etapas 5 – Archivo: Los modelos superados se trasladan al stage **Archived**, preservando el historial completo de versiones para auditoría.

4.5.2 7.5.2 Monitoreo de Data Drift y Performance

El monitoreo post-despliegue detecta dos tipos de degradación:

Data Drift: Cambio en la distribución estadística de los features de entrada. Se monitorea mediante la prueba de Kolmogorov-Smirnov (KS) entre la distribución de referencia (datos de entrenamiento) y la distribución de producción:

$$D_{KS} = \sup_x |F_{\text{train}}(x) - F_{\text{prod}}(x)|$$

Un valor $D_{KS} > 0.1$ dispara una alerta de re-entrenamiento.

Concept Drift: Cambio en la relación entre features y variable objetivo. Se detecta comparando el accuracy del modelo en producción (evaluado sobre muestras etiquetadas periódicamente) contra el accuracy de referencia del entrenamiento.

La tabla de umbrales de alerta para el sistema HGC es:

Módulo	Métrica de Monitoreo	Umbral Alerta	Umbral Crítico
Churn	Accuracy semanal	< 75%	< 65%
CLV	RMSE mensual	> 200 Bs	> 350 Bs
Branch Perf.	MAE mensual	> Bs 500,000	> Bs 1,000,000
BCG	Silhouette Score	< 0.45	< 0.30

El re-entrenamiento se ejecuta bajo demanda mediante el script `train.py` correspondiente, el cual conecta a Snowflake, extrae los datos actualizados (incluyendo los períodos más recientes), y registra el nuevo modelo en MLflow con versión incrementada automáticamente.

El directorio `hgc-ml/experiments/` preserva los resultados históricos de cada ciclo de re-entrenamiento, permitiendo análisis de tendencia del rendimiento del modelo a lo largo del tiempo de operación del sistema.

Chapter 5

Capítulo VIII: Análisis de Series de Tiempo y Pronósticos

El módulo de series de tiempo del sistema HGC representa la capacidad más estratégica de la plataforma desde la perspectiva de la planificación operativa: la posibilidad de anticipar la demanda futura, proyectar ingresos y simular escenarios alternativos antes de comprometer recursos. Este capítulo documenta la arquitectura técnica completa del motor de pronóstico, desde la preparación de datos temporales en dbt hasta el simulador interactivo de escenarios “What-If” accesible desde el dashboard.

5.1 8.1 Base Teórica de Series Temporales en el Negocio

5.1.1 8.1.1 Conceptos de Estacionalidad, Tendencia y Ciclo en Ventas de Fast Food

Una serie de tiempo de ventas en el sector de comida rápida boliviano puede descomponerse en cuatro componentes aditivos:

$$Y_t = T_t + S_t + C_t + \epsilon_t$$

Donde:

- T_t = **Tendencia**: dirección de largo plazo en el nivel de ventas. En HGC se observa una tendencia creciente desde 2015 con aceleración post-pandemia.
- S_t = **Estacionalidad**: patrones repetitivos con período fijo. Se identifican dos ciclos primarios: semanal (viernes-sábado con pico del 35% sobre el promedio) y anual (Día de la Madre en mayo, Navidad en diciembre).
- C_t = **Ciclo**: fluctuaciones de mediano plazo asociadas a ciclos económicos de Bolivia. El ciclo del dólar y las exportaciones de gas impactan el poder adquisitivo del consumidor urbano.
- ϵ_t = **Ruido**: variación aleatoria no explicable por los componentes anteriores.

La estacionalidad en el contexto boliviano tiene particularidades que los modelos genéricos no capturan:

Evento	Impacto en Ventas	Período	Cobertura Geográfica
Carnaval de Oruro	+45% en sucursales Cbba/Oruro	Feb (variable)	Regional
Día de la Madre	+60% en todos los formatos	2° domingo de mayo	Nacional

Evento	Impacto en Ventas	Período	Cobertura Geográfica
Fiestas Patrias	+30%	6 agosto $\pm$ 3 días	Nacional
Aniversario Cbba	+25%	14 septiembre	Cochabamba
Navidad y Año Nuevo	+50%	24-25 dic, 31 dic-1 ene	Nacional
Semana Santa	-20% (cierre parcial)	Marzo-Abril (variable)	Nacional
Inicio escolar	+15% (menú infantil)	Febrero	Nacional

Para el tratamiento cuantitativo de estos eventos, el motor de inferencia los codifica como variables indicadoras binarias en el vector de features temporal:

```
features = pd.DataFrame([{
    'mes': target_date.month,
    'dia_semana': target_date.weekday(),
    'lag_1': current_lags[-1],
    'lag_7': current_lags[-7],
    'rolling_mean_7': np.mean(current_lags[-7:])
}])
```

5.1.2 8.1.2 Modelos Estadísticos y Modernos

El sistema HGC evalúa el espectro completo de modelos de pronóstico, desde los clásicos estadísticos hasta los basados en aprendizaje automático:

ARIMA (AutoRegressive Integrated Moving Average)

Modelo de referencia para series univariadas. La especificación ARIMA(p, d, q) se define como:

$$\Phi(B)(1 - B)^d Y_t = \Theta(B)\epsilon_t$$

Donde B es el operador de retardo ($BY_t = Y_{t-1}$), $\Phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ es el polinomio autorregresivo y $\Theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ es el polinomio de media móvil.

Para las ventas diarias de HGC, el modelo SARIMA(1,1,1)(1,1,1)[7] captura tanto la diferenciación necesaria para estacionarizar la serie como la componente estacional semanal.

Facebook Prophet

Prophet modela la serie como suma de componentes con regresores:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Donde $g(t)$ es el modelo de tendencia (logístico o lineal por tramos), $s(t)$ la estacionalidad mediante series de Fourier y $h(t)$ el efecto de eventos especiales definidos por el usuario.

La ventaja de Prophet en el contexto HGC es la posibilidad de incorporar los feriados bolivianos como regresores explícitos, lo cual mejora significativamente la precisión en fechas pico.

XGBoost con Features de Lag (implementado en producción)

El sistema HGC implementa en producción un modelo XGBoost Regressor entrenado con features de lag temporal:

$$\hat{Y}_{t+h} = f(Y_t, Y_{t-1}, \dots, Y_{t-6}, \bar{Y}_{t-6:t}, \text{mes}_t, \text{dow}_t)$$

Donde $\bar{Y}_{t-6:t}$ es la media móvil de los últimos 7 días y dow_t el día de la semana. Este modelo aprovecha la autocorrelación positiva de las ventas de fast food (un día con ventas altas predice un día siguiente con ventas moderadamente altas) y la estacionalidad semanal capturada en `lag_7`.

LSTM (Long Short-Term Memory)

Para versiones futuras del sistema, las redes LSTM ofrecen la capacidad de capturar dependencias temporales de largo alcance. La celda LSTM gestiona el flujo de información mediante tres compuertas:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{olvidar})$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{entrada})$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{salida})$$

5.1.3 8.1.3 Manejo de Eventos Especiales y Feriados en Bolivia

La precisión del pronóstico en fechas especiales es crítica para la planificación de inventario y personal. El sistema registra los feriados en un catálogo estructurado que alimenta tanto los modelos estadísticos como las correcciones heurísticas post-predicción.

El catálogo de eventos del año fiscal boliviano utilizado en el sistema:

Código	Descripción	Tipo	Anticipación Recomendada
BO_CARNAVAL	Carnaval (lunes y martes)	Movable	45 días
BO_SEMANA_SANTA	Venta Santo - Domingo Resurrección	Movable	30 días
BO_DIA_MADRE	2º Domingo de Mayo	Movable	60 días
BO_CORPUS	Corpus Christi (60 días post-Semana Santa)	Movable	21 días
BO_INDEPENDENCIA	8 de Agosto	Fijo	14 días
BO_ANIV_CBBA	14 de Septiembre	Fijo	14 días
BO_NAVIDAD	25 de Diciembre	Fijo	30 días
BO_ANO_NUEVO	1 de Enero	Fijo	7 días

5.2 8.2 Preparación y Agregación Temporal (dbt)

5.2.1 8.2.1 Modelado de Series de Tiempo: Granularidades

El sistema HGC procesa datos temporales en tres granularidades, cada una con su propósito analítico específico:

Granularidad Diaria – Para el pronóstico operativo (stock, personal): Fuente: `fact_ventas_detalle` → `JOIN dim_fecha` → `GROUP BY fecha_venta, id_sucursal_sk`

Granularidad Semanal – Para planificación de semana siguiente: Agregación desde diario con `DATE_TRUNC('week', fecha_venta)`

Granularidad Mensual – Para presupuesto y reportes directivos: Agregación desde diario con `DATE_TRUNC('month', fecha_venta)`

La tabla `mart_ventas_historicas` en el schema GOLD consolida la granularidad diaria que alimenta el motor de pronóstico:

```

{{ config(materialized='table') }}

with diario as (
  select
    to_date(cast(id_fecha_sk as varchar), 'YYYYMMDD') as fecha,
    id_sucursal_sk,
    sum(monto_subtotal_neto) as ventas_reales,
    count(distinct nro_pedido_dd) as num_transacciones,
    sum(cantidad_vendida) as volumen_pedidos
  from {{ ref('fact_ventas_detalle') }}
  group by 1, 2
)
select
  fecha,
  id_sucursal_sk,
  ventas_reales,
  num_transacciones,
  volumen_pedidos,
  -- Lag features pre-calculados para consumo rápido
  lag(ventas_reales, 1) over (
    partition by id_sucursal_sk
    order by fecha
  ) as ventas_lag_1,
  lag(ventas_reales, 7) over (
    partition by id_sucursal_sk
    order by fecha
  ) as ventas_lag_7,
  avg(ventas_reales) over (
    partition by id_sucursal_sk
    order by fecha
    rows between 6 preceding and current row
  ) as rolling_mean_7d
from diario
order by id_sucursal_sk, fecha

```

5.2.2 8.2.2 Técnicas de Lagging y Ventanas Móviles

Las funciones de ventana (Window Functions) de Snowflake/SQL son la herramienta principal para crear features temporales sin necesidad de self-joins costosos. Las tres familias de window functions empleadas en el sistema son:

LAG: Accede al valor de una fila anterior en la partición ordenada

$$\text{lag}_k(Y_t) = Y_{t-k}$$

Ventana de media móvil (ROWS BETWEEN):

$$\bar{Y}_{t-k:t} = \frac{1}{k+1} \sum_{i=0}^k Y_{t-i}$$

Ventana de suma acumulada (RANGE UNBOUNDED PRECEDING):

$$\text{CumSum}(Y_t) = \sum_{i=1}^t Y_i$$

La siguiente tabla documenta todos los lag features implementados en el sistema, su período de retardo y su justificación estadística:

Feature	Retardo	Justificación	Uso
ventas_lag_1	1 día	Autocorrelación AR(1)	Pronóstico corto plazo
ventas_lag_7	7 días	Estacionalidad semanal	Captura patrón día-semana
ventas_lag_14	14 días	Verificación de estabilidad	Corrección de outliers
rolling_mean_7	Ventana 7d	Suavizado tendencia local	Feature principal XGBoost
rolling_std_7	Ventana 7d	Volatilidad local	Bandas de confianza
rolling_mean_30	Ventana 30d	Tendencia mensual	Corrección de deriva

5.2.3 8.2.3 Calidad de Datos Temporales

Las series de tiempo presentan tipos específicos de problemas de calidad que requieren tratamiento diferenciado:

Vacíos temporales (gaps): Días sin registros de ventas pueden deberse a cierres por feriados, problemas de conectividad del POS, o festivos no catalogados. El sistema los detecta mediante generación de calendario completo y LEFT JOIN:

```
with calendario as (
  select dateadd(day, seq4(), '2015-05-15'::date) as fecha
  from table(generator(rowcount => 4000))
),
ventas_completas as (
  select
    c.fecha,
    v.id_sucursal_sk,
    coalesce(v.ventas_reales, 0) as ventas_reales,
    case when v.ventas_reales is null then 1 else 0 end as es_vacio
  from calendario c
  left join mart_ventas_diarias v on c.fecha = v.fecha
)
```

Outliers extremos: Picos anómalos por eventos no registrados o errores de captura. Se aplica el criterio IQR con factor 3.0 (más permisivo que el estándar 1.5 para respetar picos legítimos de feriados):

$$\text{Outlier si: } Y_t < Q_1 - 3 \cdot IQR \text{ o } Y_t > Q_3 + 3 \cdot IQR$$

Cambio estructural: Apertura de nuevas sucursales o cambios de formato que alteran el nivel base de la serie. Se detecta mediante pruebas de Chow o inspección visual del rolling mean a 90 días.

5.3 8.3 Lógica del Simulador y Motor de Proyecciones

5.3.1 8.3.1 Arquitectura del Simulador de Escenarios

El Simulador CBBA es la pieza central del módulo de series de tiempo. Permite al gerente regional responder preguntas del tipo: “¿Qué pasaría con mis ventas en los próximos 6 meses si aumento la inversión en marketing un 40% y contrato 3 empleados adicionales?”.

La arquitectura de procesamiento es un pipeline de tres etapas:

Frontend (sliders) → API Request (POST /api/time-series/simulate)

Node.js Backend (simulator.service.js)

[Cache Hit] → JSON local pre-calculado

[Cache Miss] → `exec('python inference.py branchId mkt price emp')`

`inference.py`

Conexión Snowflake
`SELECT` histórico 14 días

Cargar modelo XGBoost (.pkl)

Loop 180 días (pronóstico recursivo)
Retorna JSON (stdout)

El sistema de caché utiliza una clave compuesta por los parámetros de la simulación:

```
const cacheKey = `${branchId}_${mkt}_${price}_${employees}`;  
const CACHE_FILE = `data/sim_result_${cacheKey}.json`;
```

Esto significa que una simulación con los mismos parámetros se sirve instantáneamente desde disco sin ejecutar el script Python, reduciendo la latencia de respuesta de ~8 segundos a <50 ms.

5.3.2 8.3.2 Pronóstico Recursivo a 180 Días

El motor de inferencia genera proyecciones para los 180 días siguientes al último dato histórico disponible. El algoritmo es recursivo: cada predicción $\hat{Y}_{t+i}$ se incorpora al vector de lags para calcular $\hat{Y}_{t+i+1}$:

```
current_lags = last_sales[-14:] # Inicialización con datos reales  
  
for i in range(1, 181):  
    target_date = last_date + timedelta(days=i)  
  
    features = pd.DataFrame([  
        'mes': target_date.month,  
        'dia_semana': target_date.weekday(),  
        'lag_1': current_lags[-1],  
        'lag_7': current_lags[-7],  
        'rolling_mean_7': np.mean(current_lags[-7:])  
    ])  
  
    if model:
```

```

    base_pred = float(model.predict(features)[0])
else:
    base_pred = np.mean(current_lags) # Fallback estadístico

# Aplicar impacto What-If
final_pred = base_pred * mkt_impact * price_impact * emp_impact
final_pred = max(0, final_pred)

current_lags.append(final_pred)

forecast.append({
    "date": target_date.strftime("%Y-%m-%d"),
    "ventas": round(final_pred, 2),
    "upper": round(final_pred * 1.15, 2),
    "lower": round(final_pred * 0.85, 2)
})

```

El pronóstico recursivo acumula incertidumbre a medida que el horizonte se aleja. Las bandas de confianza del $\pm 15\%$ sobre el valor puntual representan esta incertidumbre creciente de forma simplificada. En versiones futuras, se implementará propagación formal de intervalos de predicción mediante simulación Monte Carlo.

5.3.3 8.3.3 Fórmulas de Impacto What-If

Los tres parámetros controlables del simulador tienen funciones de impacto calibradas con elasticidades estimadas del mercado boliviano de fast food:

Impacto de Marketing (inversión mensual en Bs):

$$\text{mkt_impact} = 1 + \frac{\text{mkt} - 2,500}{1,000} \times 0.04$$

Interpretación: por cada 1,000 Bs adicionales sobre la inversión base de 2,500 Bs/mes, las ventas aumentan un 4%. El efecto es lineal con un punto de referencia en 2,500 Bs. Para inversiones menores a la base, el impacto es negativo.

Impacto de Precio del Combo (precio en Bs):

$$\text{price_impact} = 1 + \frac{\text{precio} - 55}{55} \times (-1.5)$$

La elasticidad precio de -1.5 indica que un incremento del 1% en el precio del combo reduce la demanda un 1.5%. El combo de referencia tiene precio base de 55 Bs. Esta elasticidad es consistente con estudios de demanda en restaurantes de comida rápida latinoamericanos, donde el consumidor es más sensible al precio que en mercados desarrollados.

Impacto de Empleados (número de empleados activos):

$$\text{emp_impact} = \min\left(1.0, 0.7 + \frac{\text{emp}}{10} \times 0.3\right)$$

El punto óptimo de productividad se alcanza con 10 empleados, donde el impacto es 1.0 (neutro). Con menos de 10 empleados, la capacidad de atención es insuficiente, reduciendo las ventas (impacto < 1). Con más de 10, el impacto no supera 1.0 (no hay sobre-productividad).

El impacto combinado se aplica multiplicativamente sobre la predicción base:

$$\hat{Y}_{\text{final}} = \hat{Y}_{\text{base}} \times \text{mkt_impact} \times \text{price_impact} \times \text{emp_impact}$$

La tabla de escenarios típicos para una sucursal con ventas base de Bs 10,000/día:

Escenario	Mkt (Bs)	Precio (Bs)	Empleados	Impacto Total	Ventas Proyectadas
Base	2,500	55	10	1.000	Bs 10,000
Agresivo	5,000	50	12	1.234	Bs 12,340
Conservador	1,500	60	8	0.791	Bs 7,910
Bajo precio	3,000	45	10	0.922	Bs 9,220
Expansión	6,000	55	14	1.140	Bs 11,400

5.3.4 8.3.4 Integración con Cache para Alta Disponibilidad

La estrategia de caché del sistema time-series implementa un patrón write-through: cuando el script Python genera un nuevo pronóstico, el resultado se persiste inmediatamente en disco antes de retornarlo al cliente:

```
exec(cmd, { maxBuffer: 1024 * 1024 * 5 }, (error, stdout, stderr) => {
  const data = JSON.parse(stdout);
  // Guardar en cache inmediatamente
  fs.writeFileSync(CACHE_FILE, JSON.stringify(data, null, 2));
  resolve(data);
});
```

El tamaño máximo del buffer de stdout es 5 MB, suficiente para los 180 puntos de pronóstico con bandas de confianza (aproximadamente 15 KB por simulación).

El directorio `hgc-back/data/` almacena los archivos de caché con nomenclatura estandarizada. Para una instalación con 8 sucursales y los parámetros de simulación más comunes, el espacio total en disco no supera los 50 MB.

5.4 8.4 Dashboards de Proyección y Simulación

5.4.1 8.4.1 Gráficos de Pronóstico con Intervalos de Confianza

El componente visual de pronóstico implementa un gráfico de área compuesta con tres series superpuestas:

1. **Histórico real** (línea continua azul): últimos 90 días de ventas efectivas
2. **Pronóstico puntual** (línea continua naranja): proyección central del modelo
3. **Banda de confianza** (área sombreada): intervalo $[\text{lower}, \text{upper}] = [85\%, 115\%]$ de la predicción

La implementación con recharts:

```
<ComposedChart data={forecastData}>
  <Area
    type="monotone"
    dataKey="upper"
    stroke="none"
    fill="#FFA50033"
    name="Límite Superior (95%)"
  />
  <Area
    type="monotone"
    dataKey="lower"
    stroke="none"
```

```

    fill="#FFA50033"
    name="Limite Inferior (95%)"
  />
  <Line
    type="monotone"
    dataKey="ventas"
    stroke="#F59E0B"
    strokeWidth={2}
    dot={false}
    name="Pronóstico"
  />
</ComposedChart>

```

El eje X muestra fechas en formato DD/MM para facilitar la lectura. El eje Y se formatea en Bs con separadores de miles. Las líneas verticales punteadas marcan la frontera entre datos históricos y proyecciones.

5.4.2 8.4.2 Simulador Interactivo CBBA

El simulador interactivo expone tres controles deslizantes al usuario:

Control	Rango	Paso	Valor Default	Unidad
Inversión Marketing	500 – 10,000	100	2,500	Bs/mes
Precio Combo	30 – 90	1	55	Bs
Nro. Empleados	3 – 20	1	10	personas

Cada cambio en un slider dispara automáticamente (con debounce de 500ms) una nueva llamada al API de simulación. El debounce evita saturar el backend con peticiones intermedias mientras el usuario arrastra el control.

El panel de métricas summary muestra, para el escenario simulado:

- **Ventas proyectadas totales** (180 días): suma de `forecast[i].ventas`
- **Crecimiento vs. base**: porcentaje de variación respecto al escenario neutro
- **Mejor mes proyectado**: mes con mayor suma de ventas diarias en el horizonte
- **Días bajo mínimo operativo**: días con ventas < umbral de rentabilidad definido por gerencia

5.5 8.5 Validación y Precisión de las Proyecciones

5.5.1 8.5.1 Backtesting de Modelos Temporales

El backtesting evalúa el modelo como si se hubiera usado en el pasado: se entrena con datos hasta la fecha T y se evalúa la precisión del pronóstico para el período $[T + 1, T + H]$, donde H es el horizonte de evaluación.

Para el sistema HGC, el backtesting se ejecuta con ventana deslizante (rolling window):

Ventana 1: Entrenamiento [2015–2023], Evaluación [Ene 2024 – Jun 2024]

Ventana 2: Entrenamiento [2015–2023 + Ene 2024], Evaluación [Feb – Jul 2024]

...

Ventana N: Entrenamiento [2015 – Nov 2024], Evaluación [Dic 2024 – May 2025]

Las métricas de backtesting agregadas para el modelo XGBoost con lag features:

Horizonte	MAPE	RMSE (Bs)	R ²	Evaluación
7 días	8.2%	4,230	0.91	Excelente

Horizonte	MAPE	RMSE (Bs)	R ²	Evaluación
30 días	12.5%	6,850	0.84	Bueno
90 días	18.7%	9,420	0.71	Aceptable
180 días	24.3%	13,100	0.58	Referencial

El MAPE (Mean Absolute Percentage Error) es la métrica de comunicación preferida con la gerencia por su interpretabilidad directa: “El modelo se equivoca en promedio un 8.2% para el horizonte semanal”.

5.5.2 8.5.2 Comparativa Real vs. Projectado

El dashboard incluye una vista de validación continua que superpone las ventas reales con las proyecciones del período anterior. Esta visualización cumple dos funciones:

1. **Transparencia:** muestra al usuario final que el modelo no es perfecto, estableciendo expectativas realistas
2. **Calibración:** permite al equipo técnico identificar patrones sistemáticos de sub/sobrepredicción

Los desvíos sistemáticos más comunes observados en el sistema HGC y sus causas:

Desvío Observado	Causa Probable	Corrección Implementada
Subpredicción en mayo	Día de la Madre no en features	Agregar indicador BO_DIA_MADRE
Sobrepredicción en Semana Santa	Cierre parcial no modelado	Flag es_feriado_cierre
Subpredicción fin de mes	Quincena/fin de mes	Feature día_del_mes
Desvío por apertura nueva suc.	Cambio estructural	Segmentación por sucursal

El proceso de comparación se ejecuta mensualmente como parte del ciclo de mantenimiento del modelo. Los resultados se documentan en el directorio `hgc-ml/results/` con formato JSON estandarizado, permitiendo el análisis de tendencia de precisión a lo largo del tiempo de operación del sistema.

Chapter 6

Capítulo IX: Modelado Econométrico y Estratégico

Este capítulo detalla la implementación de los dos pilares econométricos del sistema HGC: el **Monitor de Eficiencia Operativa** y el **Optimizador de Margen por Elasticidad**. A través de modelos avanzados, la plataforma permite no solo medir la eficiencia técnica de las sucursales, sino también predecir cómo los cambios en precios afectarán la demanda y la rentabilidad.

6.1 9.1 Fundamentos de Econometría Aplicada: Caso 1 - Eficiencia Operativa (SFA)

6.1.1 9.1.1 Función de Producción Cobb-Douglas para Puntos de Venta

La función de producción es un pilar analítico que describe la relación entre los inputs aplicados en la operación diaria y los outputs obtenidos. En el contexto de la comida rápida, el sistema HGC adopta la forma funcional Cobb-Douglas, ampliamente validada en la literatura económica por su robustez empírica y flexibilidad para estimar elasticidades.

La formulación clásica de la función Cobb-Douglas es:

$$Y = A \cdot L^{\alpha} \cdot K^{\beta}$$

Donde: - Y : Output total (ej. Ventas Totales o Volumen de Transacciones). - L : Insumo de trabajo (Labor), medido en número de empleados o costos laborales. - K : Insumo de capital (Capital), representado por costos operativos, capacidad instalada e inventario. - A : Factor de Productividad Total de los Factores (PTF), indicando la eficiencia tecnológica o de gestión inherente a la sucursal. - α, β : Elasticidades parciales del producto respecto al trabajo y al capital, respectivamente.

Para su estimación lineal mediante Mínimos Cuadrados Ordinarios (MCO) o regresión cuantil, la ecuación se transforma a su forma logarítmica:

$$\ln(Y) = \ln(A) + \alpha \ln(L) + \beta \ln(K) + \epsilon$$

En el sistema HGC, esta función permite responder preguntas vitales: “Si incremento los costos operativos en un 10%, ¿en qué porcentaje aumentarán mis ingresos?”. Las elasticidades estimadas dictan la política de inversión operativa, señalando si una sucursal opera bajo rendimientos a escala crecientes, constantes o decrecientes.

6.1.2 9.1.2 Análisis de Frontera Estocástica (SFA) para la Medición de Eficiencia

El modelo Cobb-Douglas estima el comportamiento promedio de las sucursales. Sin embargo, para identificar la eficiencia técnica, HGC implementa el Análisis de Frontera Estocástica (SFA - Stochastic Frontier Analysis) mediante Regresión Cuantílica Múltiple (en el cuantil 90).

La SFA parte de la premisa de que no todas las sucursales logran la producción máxima posible dados sus insumos. La desviación de esta “frontera de máxima eficiencia” se descompone en dos términos de error: 1. v_i : Ruido estadístico aleatorio (fuera del control de la sucursal, como fallas climáticas o eventos de fuerza mayor). 2. u_i : Ineficiencia técnica (factores controlables por el gerente, como mala gestión de personal o exceso de merma).

Matemáticamente, la frontera de producción se define como:

$$Y_i = f(X_i; \beta) \cdot \exp(v_i - u_i)$$

Al utilizar la regresión cuantílica ($q = 0.90$) en el script `train.py`, el sistema estima la “mejor práctica” observada dentro de la cadena HGC:

```
# SFA via Multiple Quantile Regression
# log(Venta) = b0 + b1*log(Costo) + b2*log(Volumen)
formula = 'LOG_Y ~ LOG_X_COSTO + LOG_X_VOLUMEN'
model = smf.quantreg(formula, df).fit(q=0.90)
```

Las sucursales que se encuentran sobre o muy cerca de la curva ($u_i \approx 0$) operan con alta eficiencia técnica, dictando el estándar corporativo. Aquellas por debajo de la curva ($u_i > 0$) exhiben brechas de ineficiencia.

6.1.3 9.1.3 Definición de Insumos (Inputs) y Resultados (Outputs) Económicos

Para adaptar la teoría a la realidad de la cadena HGC, las variables abstractas se traducen en métricas de negocio precisas extraídas de las capas operativas (POS y ERP):

Output (Variable Dependiente): - Y (**Ventas Totales**): Monto subtotal neto generado en bolivianos (Bs). Este es el proxy principal de rendimiento.

Inputs (Variables Independientes): - X_{costo} (**Costo Operativo y Mercadería**): Suma del costo estándar histórico de los productos vendidos y los gastos operativos fijos de la sucursal. - X_{volumen} (**Volumen Operativo**): Cantidad total de transacciones o unidades vendidas, que actúa como proxy del nivel de esfuerzo laboral y desgaste del capital.

Estas definiciones garantizan que las recomendaciones del modelo SFA sean directamente aplicables en la gestión diaria.

6.2 9.2 Implementación de Lógica Económica en dbt

El éxito del modelado econométrico depende de la calidad e integridad de los datos preparados. La capa de transformación dbt se encarga de calcular, normalizar y empaquetar estos indicadores.

6.2.1 9.2.1 Cálculo de Indicadores de Productividad Marginal

La productividad marginal se define como el ingreso adicional generado por una unidad extra de input. En HGC, los modelos dbt de la capa de features (ej. `feat_precio_elasticidad.sql` y `mart_econometria_eficiencia_operativa`) consolidan las métricas necesarias:

```
-- Extracto conceptual de transformación dbt
select
    id_sucursal_sk,
```



```

sum(monto_subtotal_netto) as venta_total,
sum(costo_estandar_historico * cantidad_vendida) as costo_total,
sum(cantidad_vendida) as volumen_total,

-- Transformación logarítmica para Cobb-Douglas
ln(sum(monto_subtotal_netto)) as log_y,
ln(sum(costo_estandar_historico * cantidad_vendida)) as log_x_costo,
ln(sum(cantidad_vendida)) as log_x_volumen
from {{ ref('int_ventas_precios_diarios') }}
group by 1

```

Estos cálculos pre-procesados en Snowflake evitan la carga computacional en los scripts de Python y aseguran que los indicadores financieros calculados cumplan con las reglas de negocio centralizadas (SSOT - Single Source of Truth).

6.2.2 9.2.2 Integración de Datos de Costos, Merma y Recursos Humanos

Para capturar la eficiencia operativa real, el data warehouse debe enlazar información transaccional de ventas con información de costos y recursos humanos.

La integración implica: 1. **Costos:** Extraídos de `dim_producto` y ajustados en `int_ventas_precios_diarios`. 2. **Merma:** Considerada indirectamente en las desviaciones de eficiencia (la brecha u_i suele estar correlacionada con excesos de merma). 3. **Recursos Humanos:** Integrando datos de asistencia y tamaño de plantilla para estimar los costos laborales en los escenarios predictivos.

6.2.3 9.2.3 Normalización de Variables para Modelos Estadísticos

En el modelado econométrico, variables con escalas muy divergentes (ej. ventas en millones vs. volumen en miles) pueden causar inestabilidad numérica durante la inversión de matrices en MCO o distorsionar los pesos en el entrenamiento.

Por ello, la transformación logarítmica aplicada en dbt (`LOG_Y`, `LOG_X_COSTO`, `LOG_X_VOLUMEN`) cumple un doble propósito: 1. Convierte las relaciones multiplicativas en relaciones lineales, facilitando la estimación. 2. Comprime el rango dinámico de las variables financieras atenuando el efecto de valores atípicos severos (outliers). 3. Convierte los coeficientes resultantes de la regresión directamente en **elasticidades porcentuales**.

6.3 9.3 Motor de Análisis Estadístico (Backend & ML)

El motor econométrico se divide entre scripts batch de machine learning (Python) y APIs transaccionales en tiempo real (Node.js).

6.3.1 9.3.1 Procesamiento de Optimización de Recursos y SFA

El script `hgc-ml/scripts/econometrics/efficiency-monitor/train.py` implementa el pipeline SFA. Tras ajustar el modelo cuantílico ($q=0.90$), se calculan las métricas clave de eficiencia para cada sucursal:

1. **Predicción de Frontera** (V_{frontier}): El valor máximo teórico de ventas que una sucursal podría haber generado dados sus inputs actuales.

```
df['V_FRONTIER'] = np.exp(model.predict(df))
```

2. **Score de Eficiencia:** El porcentaje del potencial máximo que la sucursal logró concretar. Se recorta (clip) a 100% para compensar ligeras sobreestimaciones del cuantil 90.

```
df['SCORE_EFICIENCIA'] = (df['VENTA_TOTAL'] / df['V_FRONTIER'] * 100).clip(upper=100)
```

3. **Brecha de Ingresos (Monetaria):** La diferencia absoluta en bolivianos entre las ventas potenciales y las ventas reales. Este es el dinero “dejado sobre la mesa” debido a ineficiencias operativas.

```
df['BRECHA_INGRESOS'] = (df['V_FRONTIER'] - df['VENTA_TOTAL']).clip(lower=0)
```

Los metadatos del modelo (Intercepto, β_{costo} , β_{volumen} , Pseudo- R^2) y el dataset resultante se exportan en formato JSON a la capa Backend.

6.3.2 9.3.2 Desarrollo de Controladores para Análisis de Eficiencia

El backend en Express expone la información econométrica a través del archivo `hgc-back/src/econometrics/econometrics`. Su arquitectura prioriza respuestas de baja latencia mediante la lectura directa de cachés JSON pre-calculados, implementando consultas Snowflake solo como estrategia de fallback.

```
exports.getEfficiencyData = async (req, res) => {
  const DATA_PATH_EFFICIENCY = path.join(__dirname, '../data/efficiency_results.json');
  try {
    if (fs.existsSync(DATA_PATH_EFFICIENCY)) {
      const fullData = JSON.parse(fs.readFileSync(DATA_PATH_EFFICIENCY, 'utf8'));
      // fullData incluye { metadata, data }
      return res.json(fullData);
    }
    res.status(404).json({ error: "Efficiency data not found. Please run ML training." });
  } catch (err) {
    res.status(500).json({ error: err.message });
  }
};
```

Este controlador alimenta la vista principal del dashboard. Del mismo modo, expone endpoints paralelos para el análisis de dispersión histórica (`getHistoricalScatter`) y la obtención de coeficientes de elasticidad de precios (`getElasticityCoefficients`), permitiendo análisis microeconómicos granulares por SKU de producto.

6.3.3 9.3.3 Generación de Insights Prescriptivos

Más allá de mostrar gráficos, el sistema transforma la matemática en lenguaje gerencial. Basado en el SCORE_EFICIENCIA y la BRECHA_INGRESOS, el sistema emite recomendaciones de acción prescriptivas:

Rango de Eficiencia	Interpretación del Modelo	Recomendación Prescriptiva Generada
95%	Óptimo (Sobre la frontera)	Operación benchmark. Analizar prácticas para replicar en otras sucursales.
80% - 94%	Rendimiento Estándar	Mantener operación, optimizar gestión de horarios valle.
65% - 79%	Ineficiencia Moderada	Auditar procesos de merma y realizar re-capacitación de personal operativo.
< 65%	Ineficiencia Crítica	Intervención gerencial prioritaria. Reducir costos fijos o implementar agresiva campaña local.

6.4 9.4 Caso 2 - Optimizador de Margen e Inferencia de Elasticidad-Precio

El segundo caso de estudio econométrico en HGC se enfoca en el **Análisis de Elasticidad de la Demanda**. Este modelo permite entender la sensibilidad de los clientes ante variaciones en los precios de los productos

clave.

6.4.1 9.4.1 Modelo Log-Log de Elasticidad

Para estimar la elasticidad, el sistema utiliza un modelo de regresión lineal en forma logarítmica (Log-Log), el cual asume una elasticidad constante a lo largo de la curva de demanda:

$$\ln(Q) = \beta_0 + \beta_1 \ln(P) + \sum \gamma_i X_i + \epsilon$$

Donde: - Q : Cantidad vendida (Demanda). - P : Precio unitario del producto. - β_1 : El coeficiente de interés, que representa directamente la **Elasticidad-Precio de la Demanda**. - X_i : Variables de control (ej. temporalidad, promociones).

Un valor de $\beta_1 = -1.5$ indica que por cada 1% que aumentemos el precio, la demanda caerá un 1.5%.

6.4.2 9.4.2 Implementación del Optimizador de Margen

El script `hgc-ml/scripts/econometrics/price-optimizer/train.py` entrena este modelo para cada producto (SKU) del menú. Los resultados se integran en el “Price Optimizer”, una herramienta de simulación “What-If” donde el usuario puede: 1. Ajustar el precio sugerido de un producto. 2. Visualizar la caída o aumento esperado en la demanda (Q). 3. Estimar el impacto neto en el margen de contribución total.

Este modelo es crítico para la estrategia de precios de HGC, permitiendo identificar productos “inelásticos” (donde se puede subir el precio sin perder mucha venta) y productos “elásticos” (donde una pequeña rebaja puede disparar el volumen).

6.5 9.5 Dashboard de Inteligencia Estratégica (Frontend)

El frontend (Next.js y Recharts) materializa los resultados econométricos en visualizaciones tácticas para la toma de decisiones.

6.5.1 9.5.1 Visualización de la Frontera de Eficiencia por Sucursal

El gráfico principal del módulo de Eficiencia consiste en un diagrama de dispersión (Scatter Plot) donde el Eje X representa los Inputs Agregados (ej. Costos) y el Eje Y las Ventas Totales.

- Se dibuja una **curva de regresión** que representa la Frontera de Eficiencia Estimada.
- Cada punto representa una sucursal.
- La distancia vertical entre un punto y la curva representa la **BRECHA_INGRESOS** (la ineficiencia).

Las sucursales se colorean dinámicamente según su score de eficiencia (Verde > 90%, Amarillo 75-90%, Rojo < 75%), permitiendo a los directivos detectar sucursales sub-rendidoras con un solo vistazo.

6.5.2 9.5.2 Mapas de Calor y Rankings de Desempeño Operativo-Económico

Adicionalmente, se despliega una tabla de posiciones interactiva (Ranking):

Rango	Sucursal	Ventas Reales	Ventas Potenciales	Brecha (Bs)	Eficiencia
1	Cbba Norte	Bs 850,000	Bs 860,000	- Bs 10,000	98.8%
2	Prado	Bs 920,000	Bs 980,000	- Bs 60,000	93.8%
...	...	...	...	...	...
8	Quillacollo	Bs 410,000	Bs 650,000	- Bs 240,000	63.0%

La interfaz permite ordenar por brecha monetaria absoluta, ayudando a priorizar intervenciones. Aunque una sucursal pequeña tenga un score bajo (ej. 60%), el esfuerzo gerencial debe enfocarse en la sucursal donde la brecha en bolivianos represente mayor pérdida para la cadena.

6.6 9.6 Despliegue y Aplicación en la Toma de Decisiones

6.6.1 9.6.1 Auditoría de Resultados Económicos

La salida del modelo econométrico se somete a validaciones de negocio. El pseudo- R^2 reportado por el ajuste cuantílico proporciona una medida de la bondad de ajuste de la frontera estocástica:

```
'R_SQUARED': float(model.prsquared)
```

Un $R^2 > 0.70$ confirma que los parámetros seleccionados (costos y volúmenes) explican de manera robusta la varianza en los ingresos de HGC, garantizando que el análisis está correctamente fundamentado en las variables determinantes reales del negocio y no en variaciones espurias.

6.6.2 9.6.2 Impacto de las Recomendaciones Econométricas en el ROI del Proyecto

La cuantificación de la BRECHA_INGRESOS representa el **Retorno de Inversión (ROI) potencial directo** de la implementación del módulo de Inteligencia de Negocios de HGC.

Al proporcionar la cifra exacta del dinero perdido por ineficiencia técnica (por ejemplo, Bs 500,000 consolidados mensuales en toda la cadena), el sistema justifica las decisiones estratégicas de reducción de costos y reestructuración operativa. Las intervenciones focalizadas dictadas por el sistema permiten a la cadena desplazar sus sucursales ineficientes hacia arriba en el gráfico, cerrando la brecha con la frontera estocástica y garantizando que el capital de trabajo y los recursos humanos operen en su capacidad máxima teórica.