

Módulo de Predicciones

Data Mining y Machine Learning aplicado a la base de clientes de HGC

1. Problemática y Objetivos

Hermanos Golden Chicken opera una base de más de 300,000 clientes registrados distribuidos en sus sucursales de La Paz, El Alto, Santa Cruz y Cochabamba. Durante mucho tiempo, esa masa de datos existió en los sistemas transaccionales sin que pudiera convertirse en conocimiento operativo: la empresa sabía cuánto había vendido en el pasado, pero no tenía herramientas para anticipar el comportamiento futuro de sus clientes.

Dos preguntas concretas quedaban sin respuesta en el día a día del área comercial. La primera: ¿qué clientes representan el mayor valor económico para la empresa, y cuánto vale realmente cada uno? La segunda, quizás más urgente: ¿cuáles de esos clientes están dejando de comprar, y cuánto revenue está en riesgo si no se actúa? Sin esa información, las campañas de retención se diseñaban de forma genérica, con presupuestos distribuidos uniformemente sobre toda la base cuando en realidad el 80% del valor estaba concentrado en una fracción de los clientes.

El presente módulo fue diseñado para dar respuesta a ambas preguntas mediante modelos predictivos basados en datos reales de Snowflake. Los objetivos específicos fueron:

- Construir un modelo de regresión que estime el **Customer Lifetime Value (CLV)** histórico de cada cliente, y a partir de él segmentar la base en grupos con comportamiento diferenciado.
- Construir un modelo de clasificación binaria que identifique qué clientes están en **riesgo de fuga (Churn)**, con suficiente anticipación como para implementar acciones de retención.
- Integrar ambos resultados en el sistema de Business Intelligence del proyecto, de modo que sean consultables desde el dashboard sin necesidad de ejecutar código adicional.

2. Arquitectura del Entorno de Ciencia de Datos

La infraestructura de datos de HGC sigue una arquitectura medallón de tres capas. La capa **Bronze** almacena los datos tal como llegan de los sistemas fuente (POS, app, delivery). La capa **Silver** los normaliza y limpia. La capa **Gold** contiene los modelos dimensionales ya procesados, y es el punto de entrada de todos los análisis de negocio.

Para los modelos predictivos, las tablas de Gold que actúan como fuente de verdad son cuatro:

- **FACT_VENTAS_DETALLE**: cada línea de venta con monto, producto, cliente, sucursal y fecha.
- **DIM_CLIENTE**: datos maestros del cliente incluyendo segmento, rango de edad y género.

- **DIM_SUCURSAL**: dimensión de sucursales con ciudad, tipo de formato y fecha de apertura.
- **FACT_ESTADO_LEALTAD_MENSUAL**: nivel de lealtad mensual por cliente (Oro, Plata, Bronce).

Un paso fundamental fue la materialización de dos **One Big Tables (OBT)** directamente en Snowflake, en el schema **TRAINING_DATASETS**. Este enfoque centraliza en una sola tabla toda la información que el modelo necesita, eliminando la necesidad de ejecutar joins complejos en cada ejecución del notebook:

Tabla OBT	Registros	Función
OBT_CUSTOMER_LIFETIME_VALUE	300,000	Dataset de entrenamiento para el modelo CLV
OBT_CHURN_PREDICTION	300,000	Dataset de entrenamiento para el modelo Churn

Tabla 9.1 — OBTs materializadas en HGC_DW.TRAINING_DATASETS

El entorno de experimentación se construyó con **Jupyter Notebooks** como interfaz principal, **scikit-learn** y **XGBoost** para el entrenamiento de modelos, y **MLflow** para el registro, versionado y exposición de los modelos entrenados. Una vez entrenados, los modelos se sirven mediante endpoints HTTP que el backend del sistema consume en tiempo real.

Las credenciales de acceso a Snowflake se gestionan a través de un archivo **.env** centralizado, con el rol **ROL_HGC_DBT** como principal, lo que garantiza que los notebooks siempre acceden al mismo schema de producción y los resultados son reproducibles entre sesiones.

3. Modelos Predictivos de Cliente

Esta sección describe los dos modelos que componen el núcleo del módulo de predicciones orientado al cliente. Ambos comparten la misma base de datos y el mismo pipeline de preparación, pero responden a preguntas distintas y se evalúan con métricas diferentes.

3.1 Predicción de Churn (Fuga de Clientes)

Antes de entrenar el modelo, fue necesario definir operacionalmente qué significa que un cliente haya hecho churn. Tras revisar la distribución de recencia en la base de datos, se estableció un umbral de **90 días de inactividad**: un cliente que no registra ninguna compra en ese período es clasificado como churn. La variable target binaria **TARGET_ES_CHURN** fue calculada comparando la fecha de última compra de cada cliente con la fecha de corte del dataset.

Una decisión de diseño particularmente importante fue excluir **RECENCIA_DIAS** del conjunto de features. Esta variable indica cuántos días han pasado desde la última compra del cliente — y es, por construcción, el predictor más directo del target. Incluirla habría generado *data leakage*: el modelo habría aprendido a replicar exactamente la definición del target en lugar de detectar patrones previos al abandono. Los features finales utilizados fueron:

- **FEATURE_FRECUENCIA_HISTORICA**: número total de visitas o transacciones del cliente.

- **FEATURE_MONTO_GASTO_HISTORICO**: monto total acumulado en toda su relación con HGC.
- **FEATURE_TICKET_PROMEDIO**: gasto promedio por visita.
- **RANGO_EDAD**: grupo etario del cliente, codificado como variable categórica.

300,000 Clientes analizados	112,426 Clientes en churn	37.5% Tasa de churn	Bs 278.7M Revenue en riesgo
---------------------------------------	-------------------------------------	-------------------------------	---------------------------------------

Una tasa de abandono del 37.5% sobre una base de 300,000 clientes implica que más de un tercio de la cartera no ha comprado en los últimos tres meses. El revenue asociado a esos clientes supera los Bs 278 millones, lo que convierte al problema de retención en una prioridad financiera concreta, no solo en un ejercicio analítico.

Se entrenaron y compararon cuatro algoritmos de clasificación, evaluados principalmente por AUC-ROC dado el desbalance de clases (62.5% activos vs 37.5% churn). Todos los modelos se entrenaron con *class_weight='balanced'* para compensar ese desbalance:

Modelo	Accuracy	AUC-ROC	F1-Churn	Recall-Churn
Logistic Regression ✓	58.7%	0.6275	0.523	0.604
Random Forest	59.6%	0.6258	0.511	0.564
Gradient Boosting	64.2%	0.6269	0.262	0.169
XGBoost	58.8%	0.6270	0.522	0.601

Tabla 9.2 — Comparativa de modelos de Churn. ✓ indica modelo campeón.

Logistic Regression fue seleccionado como modelo campeón, con el AUC-ROC más alto (0.6275) y el mejor equilibrio entre recall y F1. Es relevante aclarar que un AUC de 0.63, en apariencia conservador, es un resultado esperable y correcto dado el diseño intencional del experimento: sin acceso a recencia, el modelo debe detectar patrones sutiles de comportamiento. Que el modelo logre discriminar por encima del azar demuestra que efectivamente existen señales útiles en frecuencia y monto.

El análisis de importancia de features confirmó que **FEATURE_FRECUENCIA_HISTORICA** es el predictor dominante (coeficiente 0.46), seguido de la variable de edad con contribuciones menores. Este hallazgo es coherente con la intuición de negocio: un cliente que visita regularmente tiene una relación más sólida y es menos probable que abandone de forma abrupta.

3.2 Estimación de Customer Lifetime Value (CLV)

El Customer Lifetime Value fue definido como el monto total gastado por cada cliente durante toda su relación histórica con HGC, calculado a partir de la suma de

MONTO_SUBTOTAL_NETO en la tabla de ventas. Esta definición de CLV histórico fue preferida sobre modelos probabilísticos de CLV futuro — como BG/NBD o Pareto/NBD — considerando el nivel de madurez analítica del proyecto y la disponibilidad de datos históricos suficientes para construir un modelo de regresión estable.

Los features contruidos para el modelo recogen el comportamiento acumulado del cliente:

- **FEATURE_FREQ_TOTAL**: número total de transacciones registradas.
- **FEATURE_CANTIDAD_ARTICULOS**: total de artículos comprados en toda su historia.
- **FEATURE_ANTIGUEDAD_DIAS**: días desde la primera compra hasta la fecha de corte.
- **FEATURE_TICKET_PROMEDIO**: monto promedio por transacción.

300,000 Clientes analizados	Bs 803.8M Revenue total	Bs 2,679 CLV promedio global	3,828,721 Pedidos totales
---------------------------------------	-----------------------------------	--	-------------------------------------

La distribución del CLV es marcadamente asimétrica: la mayoría de los clientes tienen un CLV relativamente bajo, mientras un grupo reducido concentra un volumen desproporcionado del revenue total. Este patrón es consistente con la regla de Pareto documentada en la industria de restaurantes, y refuerza la necesidad de segmentar para priorizar recursos de retención.

Modelo	R ² (aprox.)	Evaluación
Linear Regression	0.72	Línea base aceptable
Ridge Regression	0.72	Sin mejora respecto a lineal
Random Forest	0.89	Captura no linealidades
Gradient Boosting	0.91	Excelente generalización
XGBoost ✓	0.93	Modelo campeón — mejor ajuste

Tabla 9.3 — Comparativa de modelos de CLV (R² sobre conjunto de prueba). ✓ modelo campeón.

XGBoost fue seleccionado como modelo campeón con un R² de 0.93, lo que indica que el modelo explica el 93% de la variabilidad del CLV histórico. Este nivel de ajuste es técnicamente coherente: frecuencia, artículos y ticket promedio son determinantes directos del CLV histórico, y XGBoost tiene la capacidad de capturar las interacciones no lineales entre ellas. El modelo fue registrado en MLflow como *HGC_CLV_Model_Pro* para su trazabilidad y consumo desde el backend.

Sobre las predicciones del modelo se aplicó **K-Means con cuatro clusters** para segmentar la base de clientes:

Segmento	Perfil	Acción recomendada
VIP	Alto CLV, alta frecuencia	Fidelización y beneficios exclusivos
Frecuente	CLV medio-alto, visita regular	Programa de puntos y cross-selling

Segmento	Perfil	Acción recomendada
Nuevo	CLV en formación, baja antigüedad	Captación y primera recompra
Inactivo	Bajo CLV, baja frecuencia	Campañas de reactivación

Tabla 9.4 — Segmentación de clientes basada en predicciones CLV.

El análisis de inteligencia de segmentos — calculado sobre las dimensiones de ciudad, sucursal y nivel de lealtad — reveló que los clientes con Nivel Oro concentran el mayor revenue total, y que existen diferencias significativas de CLV promedio entre ciudades y entre sucursales. Esto sugiere que el perfil del cliente captado por cada unidad de negocio es distinto, y que las estrategias de retención deberían adaptarse a esa heterogeneidad en lugar de aplicarse de forma uniforme.

4. Logros: Métricas de Precisión e Impacto en el Negocio

Una vez completado el ciclo de entrenamiento y evaluación de ambos modelos, los resultados consolidados permiten trazar un cuadro claro de lo que el módulo de predicciones aporta en términos concretos. Más allá de las métricas estadísticas, el valor del trabajo se mide en cuánto ayuda a la empresa a tomar mejores decisiones con la información que ya tenía.

Indicador	Churn	CLV
Modelo campeón	Logistic Regression	XGBoost
Métrica principal	AUC-ROC: 0.6275	R ² : 0.93
Accuracy	58.7%	—
Recall (clase positiva)	60.4%	—
F1-Score	0.523	—
Clientes evaluados	300,000	300,000
Clientes identificados	112,426 en riesgo	4 segmentos clasificados
Impacto económico	Bs 278.7M en riesgo	Bs 803.8M revenue mapeado

Tabla 9.5 — Resumen consolidado de métricas y alcance de ambos modelos.

Para el modelo de Churn, el Recall de 60.4% implica que de cada 10 clientes que efectivamente abandonaron, el modelo identifica correctamente a 6 antes de que se vayan. Con una base de 112,426 churners, eso se traduce en aproximadamente 67,900 clientes en riesgo detectables, sobre los cuales la empresa puede ejecutar campañas de retención dirigidas. Considerando que el costo de retener a un cliente existente es significativamente menor que el de adquirir uno nuevo, incluso una tasa de reactivación modesta sobre ese grupo representaría un retorno

positivo.

En el caso del CLV, el R^2 de 0.93 indica que el modelo tiene capacidad predictiva suficiente para orientar la asignación diferenciada de recursos. Identificar que los clientes VIP — que representan una fracción pequeña de la base — concentran una proporción desproporcionada del revenue total es, por sí solo, suficiente para justificar tratos diferenciados en el programa de lealtad, en la asignación de descuentos y en la frecuencia de contacto.

Desde el punto de vista de la ingeniería de datos, la materialización de las OBTs en Snowflake redujo el tiempo de preparación de datos de potencialmente varias horas de consultas ad hoc a una conexión directa de segundos. Esto hace que el ciclo de experimentación sea mucho más rápido y que los notebooks sean reutilizables sin necesidad de reconstruir las consultas base.

~67,900 Clientes detectables en riesgo	Bs 803.8M Revenue mapeado por segmento	< 30 seg Tiempo de prep. de datos	2 activos Modelos versionados en MLflow
---	---	--	--

5. Resultados para el Usuario del Sistema

Los modelos entrenados no quedan confinados al entorno de Jupyter. El paso final del pipeline es su integración en el sistema de Business Intelligence de HGC, donde cualquier usuario con acceso al dashboard puede consultar los resultados sin necesidad de conocimiento técnico en machine learning o en SQL.

El sistema expone los resultados a través de dos páginas dedicadas, cada una orientada a un perfil de usuario distinto:

5.1 Página de Valor del Cliente (CLV)

Accesible desde la sección Predicciones del menú lateral, esta vista presenta la inteligencia de segmentos de forma visual e interactiva. El usuario puede explorar el CLV promedio y el revenue total desglosado por cinco dimensiones: segmento de cliente, ciudad, sucursal, nivel de lealtad y rango de edad. Cada dimensión tiene su propio gráfico de barras con el detalle numérico de cada grupo.

Adicionalmente, la página incluye un predictor individual: el usuario puede ingresar el perfil de un cliente nuevo — frecuencia estimada, antigüedad, cantidad de artículos — y obtener de inmediato una estimación de su CLV esperado. Esta funcionalidad permite al área comercial evaluar el potencial de un cliente antes de asignarle beneficios del programa de lealtad.

- **KPIs globales:** total de clientes, revenue total (Bs 803.8M), CLV promedio (Bs 2,679) y pedidos históricos (3,828,721).
- **Análisis dimensional:** gráficos por segmento, ciudad, sucursal, nivel de lealtad y rango de edad.

-
- **Predictor individual:** estimación de CLV en tiempo real para un perfil de cliente ingresado manualmente.

5.2 Página de Fuga de Clientes (Churn)

Esta página cumple una función dual: mostrar el estado actual del riesgo de abandono en la base de clientes, y permitir evaluar el riesgo individual de un cliente antes de contactarlo. La sección descriptiva muestra los grupos de riesgo — alto, medio y bajo — con el número de clientes en cada categoría y el revenue que representan.

La sección predictiva funciona como una herramienta de diagnóstico previo al contacto: el agente de retención ingresa los datos del cliente (frecuencia histórica, gasto acumulado y rango de edad) y el sistema devuelve un veredicto — cliente saludable o fuga inminente — con un indicador visual de nivel de riesgo. El modelo prioriza frecuencia y monto de gasto como señales, sin depender de recencia, lo que permite evaluar clientes cuyo historial de inactividad aún no es suficiente para clasificarlos manualmente.

- **Panel de riesgo global:** grupos alto, medio y bajo con conteo de clientes y revenue en riesgo.
- **Gráfico por edad:** distribución de la tasa de churn por grupo etario del dataset de entrenamiento.
- **Predictor individual:** veredicto de riesgo con gauge visual basado en el modelo campeón.
- **Ficha técnica del modelo:** métricas de validación visibles para el usuario técnico (AUC, Recall, F1).

En conjunto, ambas páginas transforman el output técnico de los modelos en herramientas operativas concretas. Un gerente puede identificar cuáles sucursales tienen los clientes de mayor valor, un analista puede detectar a tiempo qué segmento está en mayor riesgo de abandono, y un agente de retención puede evaluar el riesgo de un cliente específico antes de diseñar la oferta de reconquista. Eso es, en definitiva, el propósito del módulo: convertir datos en decisiones.

Nota metodológica: todos los resultados presentados en este capítulo fueron obtenidos ejecutando los notebooks 2_clv_segmentation.ipynb y 4_churn_prediction.ipynb sobre datos reales de producción alojados en Snowflake (cuenta IPCSTVD-EO18571, schema TRAINING_DATASETS). Las métricas reportadas corresponden a la evaluación sobre el conjunto de prueba (20% del total, holdout estratificado). Los modelos entrenados fueron registrados bajo el experimento MLflow con ID de tracking local.