



El Espejo del Negocio

Documentacion Tecnica
Modulo de Inteligencia Artificial
Conversacional

- >> phi3:mini | 3.8B parametros | Microsoft
- >> moondream | 1.8B VLM | Vision AI
- >> Ollama | IA 100% Local | Sin costo
- >> Snowflake | Text-to-SQL | HGC_DW.GOLD
- >> FastAPI + Python 3.13 | Puerto 8001

Version: 1.0

Fecha: Abril 2026

Clasificacion: Confidencial

Sistema HGC . "El Espejo del Negocio"

Version: 1.0

Fecha: Abril 2026


Modulo: Chat IA + Smart Functions + Vision + Text-to-SQL

1. Vision General

El modulo de IA conversacional del sistema HGC es una capa de inteligencia artificial completamente local integrada sobre la plataforma de analitica predictiva. Su proposito es democratizar el acceso a los datos: cualquier miembro del equipo puede hacer preguntas en espanol natural, subir documentos, analizar imagenes de dashboards y recibir respuestas ejecutivas sin necesidad de conocimientos tecnicos.

El sistema opera 100% en hardware local (sin dependencia de APIs externas como OpenAI, Gemini o Claude), garantizando privacidad total de los datos de negocio y costo operativo cero por consulta.

2. Arquitectura del Sistema



3. Modelos de Lenguaje Utilizados

3.1 phi3:mini -- Modelo Principal de Lenguaje

Atributo	Detalle
Parametros	3.8 billones (3.8B)
Tamano en disco	~2.2 GB
Cuantizacion	Q4_K_M (4 bits)
Proveedor de runtime	Ollama v0.x
Puerto	11434 (API local)
Protocolo	OpenAI-compatible REST API
Temperatura chat	0.7 (respuestas naturales)
Temperatura SQL	0.0 (maximo determinismo)
Temperatura analisis	0.4-0.6
Max tokens	512-800 segun endpoint

?Por que phi3:mini?

Es el modelo de lenguaje mas eficiente en su categoria de tamano. Desarrollado por Microsoft Research, fue entrenado con enfasis en razonamiento matematico y capacidad de seguir instrucciones complejas. A diferencia de modelos mas grandes (llama3, mistral), corre fluidamente en PCs con 8 GB de RAM sin GPU dedicada.

3.2 moondream -- Modelo de Vision

Atributo	Detalle
Parametros	1.86 billones (1.86B)
Tamano en disco	~1.7 GB (en dos partes)
Capacidad	Vision-Language Model (VLM)
Entrada	Imagen (base64) + texto prompt
Protocolo	Ollama /api/generate con campo images
Timeout	120 segundos por request

?Por que moondream?

Es el modelo de vision mas liviano disponible en Ollama que ofrece razonamiento visual real. Puede describir imagenes, leer texto en capturas de pantalla, identificar elementos de dashboards y tablas. Su pequeno tamano (~1.7 GB) permite correrlo junto a phi3:mini en el mismo equipo.

4. Implementacion -- Endpoints y Funciones

4.1 Chat General (POST /chat)

Conversacion libre con contexto del sistema HGC. El modelo conoce todos los modulos de la plataforma gracias al SYSTEM_PROMPT que se inyecta en cada llamada:

```
SYSTEM_PROMPT = ""Eres un asistente inteligente del sistema HGC (El Espejo del Negocio).
HGC es una plataforma de analitica predictiva para una empresa de retail/restaurantes en Bolivia.
El sistema incluye: CLV, Churn, BCG, Canibalizacion, Rendimiento de sucursales,
elasticidad de precios y eficiencia operativa...""
```

Casos de uso:

- "?Que es el churn de clientes?"
- "Explicame la matriz BCG"
- "?Como funciona el modelo de CLV?"
- "?Que significa elasticidad de precio?"

4.2 Reporte Ejecutivo IA (POST /smart/report)

Recibe el JSON de datos del dashboard activo y genera un reporte estructurado con:

1. Resumen de situacion actual
2. Tres hallazgos clave
3. Dos recomendaciones de accion inmediata

Los SmartButtons en cada dashboard recopilan automaticamente los datos en pantalla y los envian a este endpoint. No requiere interaccion manual del usuario para preparar el contexto.

Parametros de entrada:

```
{
  "module": "CLV Prediction",
  "data": {
    "clvEstimado": 706,
    "tier": "Plata",
    "frecuenciaPedidos": 10,
    "edadCliente": "18-25 anos"
  }
}
```

4.3 Analisis Inteligente (POST /smart/analyst)

Similar al reporte pero orientado a responder preguntas especificas del analista sobre los datos del dashboard. Funciona en modo libre (interpretacion general) o en modo pregunta-respuesta.

4.4 Text-to-SQL con Snowflake (POST /smart/query)

Este es el endpoint mas tecnico. Convierte lenguaje natural en SQL ejecutable sobre el Data Warehouse real de HGC en Snowflake.

Flujo de ejecucion en 4 pasos:

```
Pregunta usuario (espanol natural)
?

[1] phi3:mini genera SQL (temperature=0.0)
    Prompt contiene esquema real verificado de HGC_DW.GOLD
    ?

[2] clean_sql() sanitiza el SQL generado:
    - Quita bloques markdown (``sql``)
    - Extrae solo desde SELECT/WITH
    - Elimina caracteres no-ASCII (acentos)
    - Autocorrige columnas truncadas (diccionario)
    - Deduplica LIMIT duplicados
    ?

[3] Ejecuta en Snowflake via snowflake-connector-python
    Schema: HGC_DW.GOLD
    ?

[4] phi3:mini resume resultados en espanol gerencial
    (temperature=0.4, basado en datos reales devueltos)
```

Tablas habilitadas para consulta:

Tabla	Descripcion
DIM_PRODUCTO	Catalogo de productos con categoria y precio his
DIM_CLIENTE	Clientes con segmento, genero y rango de edad
DIM_TIEMPO	Calendario con ano (ANIO), mes, trimestre, feria
FACT_VENTAS_DETALLE	Transacciones detalladas de ventas
MART_VENTAS_HISTORICAS	Ventas consolidadas por sucursal y fecha
MART_SUCURSALES_CONSOLIDADO	KPIs de sucursal: tickets, ticket promedio, merm
MART_RENTABILIDAD_DIAGNOSTICA	Rentabilidad con costos, comisiones y utilidad n

Sistema de autocorreccion de columnas (COLUMN_CORRECTIONS):

phi3:mini, al ser un modelo pequeno, a veces trunca nombres de columna largos. Se implemento un diccionario de correcciones automaticas:

```
"ANO" -> "ANIO"          # El ano real en Snowflake es ANIO
"NOM" -> "NOMBRE_PRODUCTO"
"CANT" -> "CANTIDAD_VENDIDA"
"MES_NUMERO" -> "MES"
"NOMBRE_DIA" -> "DIA_SEMANA"
```

4.5 Analisis de Imagenes (POST /chat/vision)

Permite subir capturas de pantalla, graficos o cualquier imagen para que moondream las analice.

Dos formas de subir imagenes:

1. Ctrl+V -- Pegar desde el portapapeles (screenshot directo)
2. Boton ? -- Seleccionar archivo PNG/JPG desde el disco

Proceso interno:

```
# 1. Recibe imagen y la comprime para evitar OOM
img = Image.open(BytesIO(image_bytes))
img = img.resize((768, auto_height)) # Max 768px ancho
img.save(buf, format="JPEG", quality=82)

# 2. Convierte a base64 y envia a moondream
response = httpx.post("http://localhost:11434/api/generate",
    json={"model": "moondream", "prompt": question, "images": [b64]})

# 3. phi3:mini traduce la respuesta al espanol (sin modificar contenido)
```

Limitacion conocida: moondream es un modelo pequeno (1.8B). Funciona mejor con imagenes enfocadas (una tabla, un grafico especifico) que con dashboards completos. Se recomienda usar Win+Shift+S para recortar la seccion de interes antes de pegar.

4.6 Analisis de Documentos (POST /chat/document)

Soporta PDF, Word (.docx) y texto plano (.txt). El backend extrae el texto y lo procesa con phi3:mini.

Librerias de extraccion:

- PDF: PyMuPDF (fitz) -- extrae texto nativo de PDFs
- Word: python-docx -- extrae parrafos del documento
- TXT: decodificacion UTF-8 directa

Limite de contexto: 3,000 caracteres por llamada (ajustado al contexto de phi3:mini). Documentos largos se truncan con aviso al usuario.

5. Stack Tecnologico Completo

Backend (Chat API)

Componente	Tecnologia	Version
Runtime Python	Python	3.13 (venv)
Servidor ASGI	Uvicorn	Latest
Cliente LLM	openai (compatible Ollama)	Latest
Conector BD	snowflake-connector-python	Latest
Vision HTTP	httpx	Latest
PDF	PyMuPDF	Latest
Word	python-docx	Latest
Imagenes	Pillow	Latest
Variables entorno	python-dotenv	Latest

Modelos IA (Ollama)

Modelo	Uso	RAM requerida
moondream (1.8B)	Analisis de imagenes	~2.0 GB

Frontend (Next.js)

Componente	Archivo
Botones inteligentes	components/smart-buttons.tsx

6. SmartButtons -- Integracion en Dashboards

Se creo el componente reutilizable SmartButtons.tsx que se integro en todos los modulos del sistema:

Modulo	Ruta	Datos enviados al IA
BCG Clustering	/predictions/bcg-clustering	Cuadrantes, productos por categoria
Churn Prediction	/predictions/churn	Score de riesgo, factores de abandono
Cannibalization	/predictions/cannibalization	Productos cannibalizados, impacto en ventas
Branch Performance	/predictions/branch-performance	Rentabilidad por sucursal
Eficiencia Operativa	/econometrics/efficiency-monitor	Score eficiencia, brecha de ingresos
Optimizador de Precios	/econometrics/price-optimizer	Elasticidad, precio sugerido, ingresos
Espejo del Negocio	/time-series/mirror-dashboard	Ventas, mermas, ticket por sucursal
Detective Rentabilidad	/time-series/profit-detective	Cascada de rentabilidad, utilidad neta
Simulador CBBA	/time-series/cbba-simulator	Marketing, precio, empleados, proyeccion

Cada modulo tiene 3 botones:

- ? Generar Reporte -> /smart/report
- ? Analizar con IA -> /smart/analyst
- ?? Consultar BD -> /smart/query

7. Evaluacion del Sistema

7.1 Mejora en Decisiones Clave

El sistema convierte datos tecnicos en lenguaje ejecutivo. Antes, un gerente necesitaba pedir a un analista que interpretara un dashboard de CLV. Ahora hace clic en "Analizar con IA" y en 15-30 segundos tiene un analisis con recomendaciones concretas.

Impacto medible: El tiempo desde "ver un dato" hasta "tomar una decision informada" se reduce de dias (ciclo analista -> reporte -> reunion) a segundos.

7.2 Retorno Economico (ROI)

Concepto	Costo tradicional (externo)	Costo HGC IA
Servidor cloud IA	\$50-200/mes	\$0.00 (PC local)
Costo por reporte ejecutivo	\$0.10-\$0.50	\$0.00
Costo por query SQL natural	\$0.05-\$0.20	\$0.00

El unico costo fue el tiempo de implementacion. La operacion diaria tiene costo marginal cero, independientemente del volumen de consultas.

ROI proyectado: Si el equipo hace 50 consultas/dia (reportes + queries + analisis), ahorra ~\$150-300/mes respecto a soluciones cloud equivalentes.

7.3 Precision del Sistema

Funcion	Precision observada	Limitaciones
Generacion de reportes	Alta -- estructura fija garantiza coherencia	Depende de calidad de datos del dashboard
Text-to-SQL (consultas simples)	Media-Alta -- ~85% en 1er intento	Joins complejos o columnas desconocidas fallan
Analisis de imagenes	Media -- moondream 1.8B es limitado	Imagenes densas (dashboards completos) confunden
Analisis de documentos	Alta para PDFs con texto	PDFs escaneados (solo imagen) no funcionan

Mecanismos de mejora de precision implementados:

- temperature=0.0 para SQL (maximo determinismo)
- Prompt con esquema real verificado desde Snowflake
- Diccionario de autocorreccion de 20+ columnas conocidas
- Compresion de imagenes a 768px para evitar crashes

7.4 Reduccion de Errores y Perdidas

Errores de SQL corregidos automaticamente:

- Bloques markdown en SQL (sql) -> eliminados
- Acentos en nombres de columna (ANO) -> reemplazados (ANIO)
- LIMIT duplicado -> deduplicado
- Columnas truncadas (NOM, CANT) -> expandidas al nombre real

Errores de interpretacion de imagenes:

- Imagen demasiado grande -> crash OOM de moondream -> ahora se redimensiona a 768px antes de enviar
- Respuesta en ingles reinterpretada por phi3:mini -> ahora se traduce literalmente sin reescribir

7.5 Velocidad de Respuesta

Funcion	Tiempo tipico	Metodo anterior
Generar reporte	15-35 segundos	2-4 horas (analista manual)
Analisis de dashboard	15-30 segundos	1-2 horas
Query SQL natural	25-60 segundos	Requeria conocer SQL + 10-30 min
Analisis de imagen	30-90 segundos	Reunion/llamada de 30 min
Analisis de documento PDF	20-40 segundos	Lectura manual 20-60 min

> Nota: Los tiempos son altos comparados con soluciones cloud (GPT-4 responde en 2-5s) porque phi3:mini corre en CPU sin GPU dedicada. En un equipo con GPU NVIDIA, los tiempos se reducen 5-10x.

7.6 Automatizacion de Procesos

Procesos que antes eran manuales y ahora son automaticos:

1. Generacion de reportes ejecutivos -- El analista preparaba slides/Word. Ahora el boton "Generar Reporte" produce el contenido en segundos con los datos actuales del dashboard.
2. Consulta de datos historicos -- Requeria abrir Snowflake, escribir SQL, esperar resultados, interpretar. Ahora se escribe en espanol y el sistema hace todo el ciclo.
3. Interpretacion de graficos -- Las capturas de pantalla de dashboards ahora pueden "explicarse" pegando la imagen en el chat.
4. Lectura de documentos -- PDFs de proveedores, contratos o reportes externos se pueden subir y el IA extrae los puntos relevantes.

7.7 Facilidad para Entender el Resultado (Explicabilidad)

El sistema esta disenado para maxima transparencia:

- Reporte con estructura fija: Siempre incluye (1) situacion actual, (2) hallazgos clave, (3) recomendaciones. El gerente sabe exactamente donde buscar la informacion.
- SQL visible: En modo Base de Datos, el usuario puede ver el SQL exacto que se ejecuto en Snowflake. No es una "caja negra" -- puede verificar que la pregunta se interpreto correctamente.
- Datos de contexto explicitos: Los SmartButtons pasan los datos del dashboard al modelo. El analisis no es generico -- esta basado en los numeros reales que el usuario esta viendo en pantalla.
- Respuestas en espanol gerencial: El sistema prompt fuerza respuestas concisas, profesionales y orientadas al negocio, sin jerga tecnica.

7.8 Uso Real por el Equipo

Perfil de usuario objetivo:

Rol	Uso principal	Frecuencia esperada
Analista de Negocio	Queries SQL, analisis de dashboards	20-30 consultas/dia
Gerente de Sucursal	Preguntas sobre su sucursal especifica	3-5 consultas/dia
Equipo Comercial	Analisis de productos BCG, CLV de cliente	10-15 consultas/dia

Barreras de adopcion identificadas:

- Velocidad (15-60s) puede desincentivar uso frecuente -> mitigable con GPU
- Usuarios no saben que preguntar -> documentar ejemplos de queries por modulo
- Resultados inconsistentes en SQL complejo -> guiar usuarios a preguntas simples

Facilitadores de adopcion:

- Interfaz en espanol
- Botones integrados en cada dashboard (no requiere ir al chat)
- Resultados inmediatos sin necesidad de tecnicos intermediarios

8. Variables de Entorno Requeridas

```
# Snowflake
SNOWFLAKE_ACCOUNT=xxx.snowflakecomputing.com
SNOWFLAKE_USER=usuario
SNOWFLAKE_PASSWORD=contrasena
SNOWFLAKE_ROLE=SYSADMIN
SNOWFLAKE_DATABASE=HGC_DW
SNOWFLAKE_WAREHOUSE=COMPUTE_WH
SNOWFLAKE_SCHEMA=GOLD
```

9. Requisitos de Sistema

Componente	Minimo	Recomendado
CPU	Intel i5 / AMD Ryzen 5	Intel i7 / Ryzen 7
GPU	No requerida	NVIDIA 8GB+ VRAM
Disco	10 GB libres	20 GB libres
OS	Windows 10/11	Windows 11
Python	3.13	3.13
Node.js	18+	20+

10. Como Iniciar el Modulo IA

```
# 1. Verificar que Ollama este corriendo (servicio de fondo en Windows)
# Puerto 11434 debe estar activo

# 2. Iniciar Chat API
cd chat-api
.\venv\Scripts\python.exe -m uvicorn main:app --reload --port 8001

# 3. Verificar en: http://localhost:8001/
# Respuesta esperada: {"status": "HGC Chat API running", "model": "phi3:mini"}

# 4. Acceder al chat
# http://localhost:3000/chat
```

Modelos Ollama requeridos:

```
ollama pull phi3:mini      # ~2.2 GB -- Modelo principal
ollama pull moondream      # ~1.7 GB -- Analisis de imagenes
```

11. Extensiones Futuras Recomendadas

Funcionalidad	Tecnologia sugerida	Impacto
GPU acceleration	Ollama + NVIDIA CUDA	Alto -- reduce tiempos de 30s a 3s
Historial de conversaciones	SQLite o PostgreSQL	Medio -- persistencia entre sesiones
Modelo mas preciso	llama3.1:8b o mistral:7b	Medio -- mejor SQL, menos errores
Exportar reportes a PDF	reportlab o weasyprint	Medio -- utilidad directa para gerentes
Alertas automaticas	Cron job + /smart/analyst	Alto -- analisis diario automatico
Modelo de vision mejorado	llava:7b (4.5 GB)	Medio -- mejor analisis de dashboards

Documento generado automaticamente -- Sistema HGC . Modulo IA Conversacional . Abril 2026