

1. Introducción y Objetivo

Este documento constituye la **bitácora técnica completa** del proceso de modelado predictivo implementado en el Dashboard Ejecutivo de **Transportes Maya SRL**. Cubre desde la extracción de datos en Snowflake hasta la validación estadística de los modelos Auto ARIMA.

- Lectura y exploración inicial de datos (primeras filas, estructura, dimensiones).
- Limpieza y filtrado temporal.
- Análisis descriptivo univariado y multivariado.
- Descomposición de series (tendencia, estacionalidad, residuo).
- Tests de estacionariedad (ADF, KPSS).
- Análisis de autocorrelación (ACF / PACF).
- Selección automática de modelos ARIMA(p,d,q) con criterios AICc.
- Diagnóstico de residuos (Ljung-Box, normalidad, homocedasticidad).
- Proyecciones con intervalos de confianza al 80% y 95%.

2. Tabla 4 — Características Técnicas del Modelo Auto ARIMA

Característica	Descripción
Algoritmo	Auto ARIMA (Hyndman-Khandakar). Combina pruebas de raíz unitaria (KPSS), minimización de AICc y estimación por máxima verosimilitud para seleccionar automáticamente los órdenes (p, d, q) óptimos.
Tipo de aprendizaje	No supervisado (modelado estadístico de series temporales). No requiere variable objetivo pre-etiquetada; aprende patrones de los datos históricos.
Tipo de datos (fuente)	Series temporales univariadas mensuales. Datos extraídos de Snowflake (tablas FACT_EMBARQUE, FACT_CONTRATOS) y agregados a nivel empresa.
Variable objetivo	Valor numérico mensual: Total Viajes, Contratos Nuevos y Cancelados.
Variables de entrada	Únicamente la propia historia de la serie (valores rezagados y errores pasados). No se utilizan covariables externas.
Tamaño de datos requerido	Series con al menos 157 observaciones mensuales ($\approx$ 13 años). Auto ARIMA puede funcionar con menos datos, pero la calidad de la estacionalidad mejora con series largas.
Preprocesamiento aplicado	Agregación temporal por mes; imputación de valores nulos con cero (COALESCE en SQL); conversión a objeto ts con frecuencia 12 (mensual); validación con tests ADF y KPSS.
Ingeniería de características	Ninguna. El modelo se basa exclusivamente en la estructura temporal (componentes autorregresivos y de media móvil).
Parámetros del modelo	Órdenes (p, d, q) seleccionados automáticamente por auto.arima().
Hiperparámetros adicionales	stepwise = TRUE y approximation = FALSE (valores por defecto). Estacionalidad modelada con seasonal = TRUE (frequency = 12).
División de datos	No se aplica división clásica entrenamiento/prueba. Se utiliza todo el histórico para ajustar el modelo que genera la proyección futura.

Validación del modelo	Análisis de residuos: test de Ljung-Box (ausencia de autocorrelación), test de Shapiro-Wilk (normalidad) y análisis visual de homocedasticidad.
Métrica de validación	AICc (Criterio de Información de Akaike corregido) para selección; p-valor de Ljung-Box (> 0.05 indica residuos independientes).
Entrenamiento	Estimación por máxima verosimilitud (método CSS-ML). Tiempo de ejecución inferior a 1 segundo por serie en un entorno R estándar.
Predicción	Proyección puntual con intervalos de confianza al 80% y 95% para un horizonte de 12 meses.
Interpretabilidad	Moderada. Los coeficientes AR/MA pueden interpretarse como la influencia del pasado, pero la selección automática reduce la transparencia frente a un ARIMA manual.
Control de sobreajuste	El criterio AICc penaliza la complejidad excesiva del modelo, evitando la inclusión de parámetros innecesarios.
Hardware requerido	Mínimo. Procesamiento en instancia R estándar (CPU) con RAM < 2 GB.
Tiempo de entrenamiento	< 1 segundo por serie (datos hasta diciembre 2025).
Tipo de problema	Pronóstico de series temporales univariadas (regresión sobre valores pasados).
Salida del modelo	Valores numéricos proyectados para los próximos 12 meses, acompañados de bandas de confianza superior e inferior.
Visualización	Gráficos de líneas con la serie histórica, la proyección y los intervalos de confianza sombreados.
Aplicación práctica	Dashboard ejecutivo de Transportes Maya SRL para anticipar volúmenes operativos, financieros y comerciales, facilitando la planificación táctica mensual.

Tabla 4: Características Técnicas del Modelo Auto ARIMA

3. Tabla 5 — Evaluación del Modelo según Criterios de Negocio

Criterio	Descripción
Mejora en decisiones clave	Alta. Permite a la gerencia anticipar picos de demanda (viajes) y ajustar fuerza de ventas (contratos), transformando la planificación de reactiva a proactiva.
Retorno económico (ROI)	Significativo. La inversión en infraestructura analítica es mínima (software R open-source, consulta a Snowflake existente). La reducción de costos por sobre-stock de flota o falta de liquidez genera un retorno intangible pero sustancial.
Precisión del modelo	Variable según la serie. Series con alta autocorrelación temporal presentan mejor ajuste predictivo; series con alta variabilidad aleatoria producen intervalos más amplios.
Reducción de errores / pérdidas	Moderada. Evita decisiones basadas únicamente en la intuición o en el promedio móvil simple, reduciendo el error de proyección frente a métodos naïve.
Velocidad de respuesta	Instantánea. Una vez disponibles los datos del mes anterior en Snowflake, el pipeline R genera nuevas proyecciones a 12 meses en segundos, listas para el dashboard.
Automatización de procesos	Total. La conexión a Snowflake, la agregación, el ajuste de Auto ARIMA y la actualización de visualizaciones se ejecutan automáticamente sin intervención manual.
Facilidad para entender el resultado	Alta. Los gráficos de proyección con bandas de confianza son intuitivos para usuarios no técnicos. La interpretación de 'rango esperado' se alinea con el lenguaje de planificación financiera.
Uso real por el equipo	Activo. El modelo constituye el núcleo de la pestaña de Forecast del Dashboard Ejecutivo, consultado mensualmente por la gerencia general y los jefes de operaciones, finanzas y comercial.

Tabla 5: Evaluación del Modelo según Criterios de Negocio

4. Conexión y Extracción de Datos desde Snowflake

4.1 Configuración de Conexión

La conexión se establece mediante el paquete **odbc** de R usando el driver nativo de Snowflake. Las credenciales y parámetros de la instancia de producción son:

R · conexion.R

```
conectar <- function() { dbConnect( drv = odbc::snowflake(), account = "OSQTUIX-FP96275", uid =
"AIRBYTE_SVC", warehouse = "AIRBYTE_WH", database = "LOGISTICA_BI", role = "AIRBYTE_ROLE" ) }
```

4.2 Query 1 — Operaciones y Finanzas

Combina dos fuentes: **embarques** (volumen de viajes) y **finanzas** (ingresos, costos, margen), cruzándolos mediante un **FULL OUTER JOIN** por mes y sucursal. Utiliza CTEs para separar la lógica de cada subconjunto.

SQL · Query Operaciones (simplificado)

```
WITH viajes AS ( SELECT fe.VIAJE_ID, DATE_TRUNC('MONTH', fe.FECHA_SALIDA_REAL::DATE) AS MES,
fe.SUCURSAL_ORIGEN_ID AS SUCURSAL_ID, fe.ESTATUS_ENTREGA FROM LOGISTICA_BI.DATAGOZU.FACT_EMBARQUE fe
WHERE fe.FECHA_SALIDA_REAL IS NOT NULL ), viajes_agg AS ( SELECT MES, SUCURSAL_ID, COUNT(DISTINCT
VIAJE_ID) AS TOTAL_VIAJES, COUNT(DISTINCT CASE WHEN ESTATUS_ENTREGA = 'Entregado' THEN VIAJE_ID END)
AS VIAJES_ENTREGADOS, COUNT(DISTINCT CASE WHEN ESTATUS_ENTREGA = 'Cancelado' THEN VIAJE_ID END) AS
VIAJES_CANCELADOS FROM viajes GROUP BY 1,2 ), finanzas_agg AS ( SELECT DATE_TRUNC('MONTH',
ff.FECHA::DATE) AS MES, ff.SUCURSAL_ID, SUM(ff.INGRESO_BOB) AS INGRESOS_BOB,
SUM(ff.TOTAL_EGRESOS_BOB) AS TOTAL_COSTOS_BOB, SUM(ff.MARGEN_BOB) AS MARGEN_BOB FROM
LOGISTICA_BI.DATAGOZU.FACT_FINANZAS ff GROUP BY 1,2 ) SELECT COALESCE(v.MES, f.MES) AS MES, ... FROM
viajes_agg v FULL OUTER JOIN finanzas_agg f ON v.MES = f.MES AND v.SUCURSAL_ID = f.SUCURSAL_ID ORDER
BY MES, SUCURSAL_NOMBRE
```

4.3 Query 2 — Contratos y Clientes (Comercial)

Calcula métricas comerciales mensuales: **clientes nuevos** (primer contrato), **contratos nuevos**, **contratos completados** y **contratos totalmente pagados**. Usa CTEs encadenadas y un pivote final con **FULL OUTER JOIN** por dimensión.

SQL · Query Comercial (simplificado)

```
WITH contratos_base AS ( SELECT ct.CONTRATO_ID, ct.CLIENTE_ID, ct.FECHA_INICIO, ct.FECHA_FIN,
ct.ESTADO, ct.SUCURSAL_ORIGEN_ID AS SUCURSAL_ID FROM LOGISTICA_BI.DATAGOZU.FACT_CONTRATOS ct ),
primer_contrato_cliente AS ( SELECT CLIENTE_ID, MIN(FECHA_INICIO) AS primera_fecha FROM
contratos_base GROUP BY 1 ), clientes_nuevos_mes AS ( SELECT DATE_TRUNC('MONTH', pc.primer_fecha) AS
mes, cb.SUCURSAL_ID, COUNT(DISTINCT pc.CLIENTE_ID) AS clientes_nuevos FROM primer_contrato_cliente pc
JOIN contratos_base cb ON pc.CLIENTE_ID=cb.CLIENTE_ID GROUP BY 1,2 ) SELECT
COALESCE(cn.clientes_nuevos, 0) AS CLIENTES_NUEVOS, COALESCE(ctn.contratos_nuevos, 0) AS
CONTRATOS_NUEVOS, COALESCE(ctc.contratos_completados, 0) AS CONTRATOS_COMPLETADOS FROM meses m LEFT
JOIN clientes_nuevos_mes cn ON m.mes = cn.mes ... WHERE m.mes IS NOT NULL ORDER BY m.mes DESC
```

5. Preparación de Series para Modelado

Se aplica el mismo pipeline que usa el dashboard en producción: los datos crudos se agregan por mes a nivel empresa para obtener series mensuales limpias.

R · preparacion_series.R

```
# Serie Operativa: Total Viajes serie_viajes <- datos_op |> group_by(MES) |> summarise(VALOR =  
sum(TOTAL_VIAJES, na.rm=TRUE)) |> arrange(MES) # Serie Comercial: Contratos nuevos serie_contratos <-  
datos_com |> group_by(MES) |> summarise(VALOR = sum(CONTRATOS_NUEVOS, na.rm=TRUE)) |> arrange(MES) #  
Idem para: Ingresos, Margen, Costos, Clientes
```

5.1 Series disponibles por variable

Serie	Variable fuente	Tipo	Frecuencia
Ingresos (BOB)	INGRESOS_BOB	Financiero	Mensual
Total Viajes	TOTAL_VIAJES	Operativo	Mensual
Margen (BOB)	MARGEN_BOB	Financiero	Mensual
Costos (BOB)	TOTAL_COSTOS_BOB	Financiero	Mensual
Contratos Nuevos	CONTRATOS_NUEVOS	Comercial	Mensual
Clientes Nuevos	CLIENTES_NUEVOS	Comercial	Mensual

Tabla: Variables modeladas en el sistema