

CASO 4: CHURN PREDICTION

Prediccion de Fuga de Clientes

Modelo: Logistic Regression | AUC-ROC: 0.63 | Sin data leakage

HGC System | Modulo de Inteligencia Artificial | 2026

SECCION 1 - Origen del Dataset: Como se construyo en dbt

Pregunta de negocio que responde este modulo:

Cuales de mis clientes actuales tienen alta probabilidad de abandonar la empresa en los proximos 90 dias? Esta pregunta es critica para cualquier negocio de consumo masivo porque retener un cliente existente cuesta hasta 5 veces menos que adquirir uno nuevo.

Pipeline de datos: De las ventas reales al dataset de ML

El dataset NO fue creado manualmente. Es el resultado de transformaciones SQL automatizadas en dbt (Data Build Tool) que corren sobre el Data Warehouse en Snowflake. La cadena tiene 3 capas:

Capa 1 - Staging:

Los datos brutos de ventas se limpian: se estandarizan nombres, se castean tipos de datos y se eliminan duplicados.

Capa 2 - feat_clientes_comportamiento.sql (Feature Engineering):

```
SELECT
  id_cliente_nk,
  rango_edad,
  COUNT(DISTINCT nro_pedido_dd)      AS frecuencia_historica,
  SUM(monto_subtotal_netto)          AS monto_gasto_historico,
  DATEDIFF(day, MAX(fecha), TODAY()) AS recencia_dias
FROM fact_ventas_detalle
GROUP BY id_cliente_nk
```

Capa 3 - obt_churn_prediction.sql (Dataset final para ML):

```
SELECT
  id_cliente_nk,
  rango_edad,
  frecuencia_historica  AS feature_frecuencia_historica,
  monto_gasto_historico AS feature_monto_gasto_historico,
  recencia_dias         AS feature_recencia_dias,
  CASE WHEN recencia_dias >= 90 THEN 1 ELSE 0 END AS target_es_churn
FROM feat_clientes_comportamiento
```

CONCLUSION: El dataset es 100% real. Proviene del historial de compras del negocio transformado por dbt.

SECCION 2 - Correccion Critica: El Problema del Data Leakage

Que es data leakage?

Data leakage ocurre cuando el modelo recibe como input una variable que ya contiene la respuesta que se le pide predecir. Es el error mas grave en Machine Learning porque produce modelos con 100% de precision que son completamente inutil en la vida real.

El problema que encontramos:

El TARGET se definio como CHURN = 1 si RECENCIA_DIAS >= 90. La variable RECENCIA_DIAS se usaba tambien como FEATURE del modelo. Esto equivale a darle la respuesta al examen antes de darlo: el modelo simplemente aprende la regla y reporta 100% de accuracy, pero no ha aprendido nada real sobre el comportamiento del cliente.

VERSION CON LEAKAGE (incorrecto):

Features: RANGO_EDAD, FRECUENCIA, MONTO, RECENCIA_DIAS <-- TRAMPA

Resultado: Accuracy = 100% (FALSO, inutilizable en produccion)

VERSION CORREGIDA (correcto):

Features: RANGO_EDAD, FRECUENCIA, MONTO (sin recencia)

Resultado: AUC-ROC = 0.63 (REAL, util para el negocio)

LECCION: Un AUC de 0.63 honesto es infinitamente mas valioso que un Accuracy de 100% fraudulento. La diferencia entre un modelo que aprende y uno que hace trampa.

SECCION 3 - Setup y Carga de Datos

Resultado real del sistema:

MLflow Tracking URI : sqlite:///mlflow.db

Experimento : HGC_Churn_Prediction_Final

Dataset cargado : 300,000 clientes | 6 columnas

Distribucion TARGET :

Churn = 0 (Activos) : 193,157 clientes (64.4%)

Churn = 1 (Fugados) : 106,843 clientes (35.6%)

Interpretacion de negocio:

Se tienen 300,000 clientes reales. El 35.6% (106,843 clientes) no han comprado en los ultimos 90 dias. Este es el punto de partida: el modelo aprendera a distinguir entre activos y fugados basandose en sus patrones de compra historicos.

SECCION 4 - EDA: Analisis Exploratorio de Datos

Que hace esta seccion?

Antes de entrenar cualquier modelo es obligatorio entender visualmente los datos. Esta seccion analiza la distribucion de churn por grupo de edad y las diferencias de frecuencia y monto entre clientes activos vs fugados.

Hallazgo principal del EDA:

La tasa de fuga es aproximadamente igual en todos los grupos de edad (aprox. 18%). Esto confirma que la edad NO es un predictor relevante del churn en este negocio. Lo que realmente diferencia a un cliente fiel de uno en riesgo es su comportamiento de compra: frecuencia y monto historico.




Figura: churn_eda.png -- Distribucion de churn por edad y comparativa activos vs fugados

SECCION 4B - Mapa de Correlaciones

Que hace esta seccion?

Calcula la fuerza de la relacion entre cada variable y la probabilidad de churn. Un valor cercano a +1 indica relacion directa fuerte; cercano a 0 indica que la variable no aporta poder predictivo.




Figura: churn_correlaciones.png -- Mapa de calor de correlaciones entre variables y TARGET_ES_CHURN

HALLAZGO: Los clientes fugados tienen en promedio 2-3x menos compras y 2-3x menos gasto historico que los activos. La fuga es un patron de comportamiento, no de demografia.

SECCION 5 - Competencia de Modelos de Machine Learning

Por que estos 4 modelos?

En clasificacion binaria (CHURN si/no) se eligieron modelos de dos familias complementarias para garantizar que el resultado sea robusto:

Familia 1 - Modelos Lineales:

- Logistic Regression: El clasico de clasificacion binaria. Aprende una frontera lineal entre clientes que se van y los que quedan. Rapido e interpretable.
- Gradient Boosting: Construye arboles secuencialmente corrigiendo errores previos.

Familia 2 - Modelos de Ensamble:

- Random Forest: Crea cientos de arboles de decision y vota por mayoria. Robusto frente a datos ruidosos.
- XGBoost: Version optimizada del Gradient Boosting. Gana la mayoria de competencias mundiales de ML en datos tabulares.

Resultados reales de la competencia (sin data leakage):

Modelo		Accuracy		AUC-ROC		F1-Churn		Recall-Churn

LogisticRegression*		0.5877		0.6263		0.5118		0.6057
XGBoost		0.5879		0.6259		0.5115		0.6050
RandomForest		0.5900		0.6253		0.5100		0.6021
GradientBoosting		0.6556		0.6258		0.2597		0.1834

CAMPEON: LogisticRegression (AUC-ROC=0.6263, Recall-Churn=0.6057)

Por que se usa AUC-ROC y no Accuracy?

Si el 64% de los clientes son activos, un modelo que SIEMPRE dice activo tiene 64% de accuracy sin haber aprendido nada. AUC-ROC mide la capacidad real del modelo de distinguir entre churners y no-churners, independientemente del desbalance de clases.

Por que quedo Gradient Boosting con Recall=0.18?

GradientBoosting obtuvo el mayor Accuracy (65.6%) pero el peor Recall de Churn (18%). Maximizo las predicciones correctas globales a costa de NO detectar al 82% de los churners reales. Para el negocio esto es peligroso: crees que tu modelo funciona por su alto accuracy, pero estas dejando escapar a la gran mayoria de clientes en riesgo.

BENEFICIO DE LA COMPETENCIA: Revelo que GradientBoosting, el modelo con mayor accuracy, es el PEOR para este problema de negocio. Sin el torneo, podriamos haber elegido el modelo equivocado con consecuencias costosas.

SECCION 6 - Metricas de Validacion del Modelo Campeon

Curva ROC y Matriz de Confusion:




Figura: churn_roc_confusion.png -- Curva ROC (AUC=0.63) y Matriz de Confusion del LogisticRegression

Feature Importance -- Que variables usa el modelo para decidir?




Figura: churn_feature_importance.png -- Importancia relativa de cada variable en el modelo campeón

AUC-ROC = 0.6263 --> Poder de discriminacion real
 Accuracy = 0.5877 --> Exactitud global
 Recall = 0.6057 --> De cada 100 churners reales, detecta 61
 Precision= 0.4360 --> De cada 100 alertas, 44 son churners reales
 F1-Score = 0.5118 --> Balance Precision/Recall

Que significa AUC=0.63 para el negocio?

AUC=0.50 equivale a tirar una moneda al aire. AUC=1.0 seria perfecto (imposible en comportamiento humano). AUC=0.63 significa que si tomamos un churner real y un no-churner al azar, el modelo asigna mayor probabilidad de churn al churner el 63% de las veces. Con solo 3 variables de comportamiento, esto es un resultado solido y honesto.

Que significa Recall=0.61?

De cada 100 clientes que realmente van a abandonar, el modelo identifica correctamente a 61 de ellos. En la base de 106,843 churners reales, el modelo detecta a 64,845 clientes en riesgo real. Estos son los clientes a quienes dirigir la campana de retencion.

El trade-off Precision/Recall:

Con Precision=0.44, de cada 100 alertas del modelo, 44 son churners reales y 56 son falsos positivos. En marketing de retencion, este trade-off es aceptable: es mejor enviar un cupon a alguien que no lo necesita que perder a un cliente real. El costo de un cupon

es mucho menor que el costo de perder un cliente.

RESUMEN: El modelo detecta correctamente al 61% de los clientes que abandonaran. Para 300,000 clientes, eso es ~65,000 clientes priorizados para campanas de retencion.

SECCION 7 - Segmentacion Final y Resultados de Negocio

=====	
RESULTADOS: Caso 4 - Prediccion de Fuga de Clientes	
=====	
Clientes analizados	: 300,000
Modelo campeon	: LogisticRegression AUC-ROC: 0.6263
RIESGO ALTO (probabilidad > 60%):	
Clientes	: 54,586 (18.2% de la base)
Revenue en riesgo	: Bs 89,307,556
Accion	: Cupon + combo de reactivacion urgente
RIESGO MEDIO (35-60%):	
Clientes	: 216,424 (72.1% de la base)
Revenue en riesgo	: Bs 596,119,995
Accion	: Notificacion app + programa de puntos
RIESGO BAJO (< 35%):	
Clientes	: 28,990 (9.7% de la base)
Revenue asegurado	: Bs 118,384,503
Accion	: Monitoreo mensual estandar

Desglose de Riesgo Alto por Grupo de Edad:

Grupo de Edad	Clientes Totales	En Riesgo Alto	% Riesgo

18 - 25	39,814	7,326	18.4%
26 - 35	49,636	9,034	18.2%
Mayor de 35	200,802	36,546	18.2%
Menor de 18	9,748	1,752	18.0%
La tasa de riesgo es uniforme en todos los grupos de edad.			
La edad NO discrimina. El comportamiento de compra SI.			

Interpretacion estrategica para directivos:

Los 54,586 clientes de Riesgo Alto representan Bs 89.3 millones en revenue historico en peligro. Si el negocio recupera solo al 10% (5,458 clientes) mediante una campana de reactivacion con cupon, protege Bs 8.9 millones que de otro modo se perderian.

Los 216,424 de Riesgo Medio son el grupo mas voluminoso. Una estrategia de notificaciones push con combos 2x1 puede mover una fraccion hacia Riesgo Bajo.

Los 28,990 de Riesgo Bajo son la base fiel. No requieren inversion de retencion ahora.

SECCION 8 - Interpretacion Completa del Sistema en Produccion

Como funciona el modelo en produccion?

El modelo entrenado se despliega como microservicio REST mediante MLflow Models Serve en el puerto 5001. El backend de Node.js lo consulta cuando el usuario ingresa el perfil de un cliente en la pagina web, devolviendo la probabilidad de churn en milisegundos.

Los 3 niveles de la pagina web:

1. DESCRIPTIVO: Muestra el estado actual de la base de clientes: cuantos estan en riesgo alto/medio/bajo y cuanto revenue representan. Responde: donde estamos hoy?
2. PREDICTIVO: El Evaluador de Riesgo Individual permite ingresar el perfil de compra de un cliente especifico y obtener su probabilidad de churn en tiempo real. Responde: este cliente especifico se va a ir?
3. PRESCRIPTIVO: Cada nivel de riesgo tiene acciones de marketing especificas contextualizadas para un negocio de comida. Responde: que hacemos al respecto?

Como usar el Evaluador Individual correctamente:

Uso 1 - EVALUACION EN CAMPO: Un gerente de sucursal tiene un cliente frente a el. Ingresa su frecuencia y monto de compra historico y obtiene un veredicto inmediato sobre si debe ofrecerle un incentivo de retencion.

Uso 2 - DESCUBRIMIENTO DE UMBRALES: Moviendo los sliders se descubre el punto donde el modelo cambia de SALUDABLE a FUGA. Esto define los criterios para campanas masivas: por ejemplo, clientes con menos de 10 compras y menos de Bs 800 de gasto historico tienen alto riesgo de abandono.

RESUMEN EJECUTIVO CHURN:

300,000 clientes analizados | 35.6% tasa de churn historica

Modelo: Logistic Regression | AUC-ROC=0.63 | Recall=0.61

54,586 clientes Riesgo Alto | Bs 89.3M en revenue en peligro

Variable clave: Frecuencia + Monto historico de compra

La edad NO predice el churn | El comportamiento SI lo hace

Leccion: Segmentar por comportamiento, no por demografia