

CASO 2: CLV

Segmentacion Predictiva del Valor del Cliente

Customer Lifetime Value | Analisis Completo por Secciones

SECCION 1 - Origen del Dataset: Como se construyo en dbt

1.1 Pipeline de datos: De las ventas reales al dataset de ML

El dataset que alimenta el modelo de CLV NO fue creado manualmente ni inventado. Es el resultado de una cadena de transformaciones SQL automatizadas en dbt (Data Build Tool) que corren diariamente via Airflow a las 4:00 AM sobre el Data Warehouse en Snowflake. La cadena tiene 3 capas:

Capa 1 - Staging (datos crudos normalizados):

Se toman los datos brutos de ventas del sistema transaccional y se limpian: se estandarizan nombres, se castean tipos de datos y se eliminan duplicados.

Capa 2 - feat_clientes_comportamiento.sql (Feature Engineering):

Este modelo dbt cruza la tabla de clientes con la tabla de ventas detalle y calcula para cada cliente 6 metricas de comportamiento historico:

```
SELECT
  id_cliente_nk,
  rango_edad,
  SUM(cantidad_vendida)           AS cantidad_articulos_comprados,
  COUNT(DISTINCT nro_pedido_dd)   AS frecuencia_pedidos,
  SUM(monto_subtotal_netto)       AS valor_monetario_total,
  DATEDIFF(day, MAX(fecha), TODAY()) AS recencia_dias,
  DATEDIFF(day, MIN(fecha), TODAY()) AS antiguedad_dias
FROM fact_ventas_detalle
GROUP BY id_cliente_nk
```

Capa 3 - obt_customer_lifetime_value.sql (Dataset final para ML):

Selecciona las columnas clave del feature model y las renombra con prefijos estandarizados FEATURE_ y TARGET_ para que el notebook de Python las identifique automaticamente. Este modelo se materializa como TABLE en Snowflake.

```
SELECT
  id_cliente_nk,
  rango_edad,
  frecuencia_pedidos           AS feature_freq_total,
  cantidad_articulos_comprados AS feature_cantidad_articulos,
  antiguedad_dias              AS feature_antiguedad_dias,
  valor_monetario_total        AS target_clv_historico  -- Variable objetivo
FROM feat_clientes_comportamiento
```

CONCLUSION: El dataset es 100% real. Proviene del historial de compras del negocio transformado por dbt. No hay datos inventados en este pipeline.

SECCION 2 - Setup y Conexion al Entorno

Que hace esta seccion?

Carga las librerias de ciencia de datos (scikit-learn, XGBoost, MLflow, pandas), apunta MLflow a una base de datos local (mlflow.db) para registrar todos los experimentos, y carga las credenciales de Snowflake desde el archivo .env del proyecto.

Resultado real del sistema:

```
MLflow Tracking URI : sqlite:///mlflow.db
Entorno configurado correctamente
```

Interpretacion:

El mensaje confirma que el entorno esta listo. MLflow actua como el 'cuaderno de calificaciones' que va a registrar automaticamente las metricas de cada modelo durante la competencia. Esto permite comparar los resultados de forma objetiva y reproducible.

SECCION 3 - Carga de Datos desde Snowflake

Que hace esta seccion?

El notebook se conecta a Snowflake usando las credenciales del .env y ejecuta un SELECT sobre la tabla TRAINING_DATASETS.OBT_CUSTOMER_LIFETIME_VALUE. Descarga todos los registros a memoria y reporta las metricas globales del negocio.

Resultado real del sistema:

```
Dataset cargado      : 300,000 filas | 6 columnas
CLV historico total  : Bs 803,812,054.0
```

Interpretacion de negocio:

Se tienen 300,000 clientes reales con historial. La suma del valor que todos esos clientes han dejado al negocio a lo largo de su vida es de Bs 803 millones. Este es el numero que la Inteligencia Artificial aprendera a predecir cliente por cliente. Conocer este valor proyectado por cliente permite priorizar los recursos de marketing y retencion.

SECCION 4 - EDA: Analisis Exploratorio de Datos

Que hace esta seccion?

Antes de entrenar cualquier modelo, es obligatorio entender visualmente los datos. Esta seccion genera 3 graficos en el archivo clv_eda.png que permiten responder: Quien es nuestro cliente? Cuanto vale? Hay diferencias por edad?




Figura: clv_eda.png - Distribucion CLV, volumen por edad y CLV promedio por edad

Interpretacion del grafico clv_eda.png:

Panel izquierdo (Histograma de CLV): La mayoría de clientes tiene un valor historico entre Bs 700 y Bs 2,500. Existe una cola larga a la derecha con pocos clientes pero de valor muy alto (mas de Bs 3,500). Esta es la elite VIP que el negocio debe proteger a toda costa. La linea amarilla muestra el promedio del negocio.

Panel central (Cantidad de clientes por edad): Muestra cual franja etaria es la mas numerosa en la tienda. Es el mapa de trafico demografico.

Panel derecho (CLV promedio por edad): Esta es la grafica mas estrategica. No importa que grupo trae mas gente; importa que grupo deja mas dinero. Los adultos mayores tienden a tener un CLV promedio mas alto por mayor estabilidad financiera.

CONCLUSION: La empresa tiene una base de clientes diversa pero el valor real del negocio se concentra en una minoria de clientes con alta frecuencia de compra.

SECCION 5 - Mapa de Correlaciones

Que hace esta seccion?

Calcula matematicamente que tan fuerte es la relacion entre cada variable del cliente y el CLV. El resultado es un numero entre -1 y +1. Cuanto mas cerca de +1, mas directa es la relacion. Se grafica como mapa de calor en clv_correlaciones.png.




Figura: clv_correlaciones.png - Mapa de calor de correlaciones

Resultado real del sistema:

CANTIDAD_ARTICULOS	-->	+0.8209	(correlacion muy fuerte)
FREQ_TOTAL	-->	+0.7253	(correlacion fuerte)
ANTIGUEDAD_DIAS	-->	+0.2028	(correlacion debil)

Interpretacion:

La cantidad de articulos que un cliente lleva por visita (+0.82) y su frecuencia de visitas (+0.73) son los dos motores del valor economico. Son correlaciones muy fuertes.

La antiguedad importa, pero mucho menos (+0.20). Un cliente nuevo que compra frecuentemente puede superar en valor a uno de hace anos que compra poco.

DECISION TACTICA: La estrategia de marketing debe priorizar conseguir que el cliente compre MAS COSAS por visita y que VUELVA CON FRECUENCIA. Los descuentos de primera compra son menos rentables que los programas de fidelizacion continuos.

SECCION 6 - Analisis PCA (Mapa de Tribus Financieras)

Que hace esta seccion?

PCA (Analisis de Componentes Principales) es una tecnica matematica que toma las 3 variables numericas del cliente (frecuencia, articulos, antigüedad) y las comprime en 2 dimensiones para poder dibujar un mapa de todos los clientes y ver si forman grupos naturales segun su nivel de valor.




Figura: clv_pca.png - Varianza explicada y mapa de segmentos por CLV

Resultado real del sistema:

Varianza total explicada (PC1 + PC2): 96.1%

Interpretacion del grafico izquierdo - Varianza Explicada:

Este grafico de barras es el 'sello de garantia matematica'. Dice que el mapa de puntos de la derecha captura el 96.1% de toda la informacion real del comportamiento del cliente. No estamos viendo una caricatura distorsionada; es casi la radiografia completa. Con 96% de fidelidad, cualquier decision que tomemos basada en este mapa es cientificamente valida.

Interpretacion del grafico derecho - Mapa de Tribus:

Los 300,000 clientes aparecen como puntos coloreados en 4 niveles de valor: Bajo (rojo), Medio (amarillo), Alto (azul), VIP (verde).

Cuando los colores NO estan mezclados al azar sino agrupados en zonas claramente separadas, demuestra que los clientes VIP tienen un perfil matematico inconfundible y radicalmente diferente al cliente de valor bajo.

APLICACION PRACTICA: Si un cliente nuevo entra y sus primeras compras lo ubican en la zona verde del mapa, el backend puede etiquetarlo como VIP automaticamente y activar campanas de trato preferencial desde su primera transaccion.

SECCION 7 - Competencia de Modelos de Machine Learning

Por que competencia? Por que estos modelos?

En ciencia de datos no existe un unico algoritmo universal. La unica forma honesta de elegir el mejor modelo es poner a varios a competir con los mismos datos y medir objetivamente quien predice mejor. Para CLV elegimos 5 modelos de 2 familias:

Familia 1 - Modelos Lineales:

- Linear Regression: El modelo clasico. Asume que a mayor frecuencia de compras, el CLV sube proporcionalmente en linea recta.
- Ridge: Version de Regresion Lineal con penalizacion anti-sobreajuste. Util cuando hay variables muy correlacionadas entre si.

Familia 2 - Modelos de Arboles (No-lineales):

- Random Forest: Crea cientos de arboles de decision y promedia sus respuestas. Muy robusto, captura relaciones no lineales.
- Gradient Boosting: Construye arboles secuencialmente, cada uno corrigiendo los errores del anterior. Alta precision pero mas lento.
- XGBoost: La version optimizada del Gradient Boosting. Gana la mayoria de competencias mundiales de ML en datos tabulares.

Resultados reales de la competencia:

Modelo		R2	MAE	RMSE

LinearRegression	*	0.6729	466.65 Bs	591.86 Bs
Ridge		0.6729	466.65 Bs	591.86 Bs
GradientBoosting		0.6721	467.03 Bs	592.53 Bs
RandomForest		0.6717	467.37 Bs	592.92 Bs
XGBoost		0.6708	467.75 Bs	593.69 Bs
CAMPEON: LinearRegression (R2=0.6729, MAE=466.65 Bs)				

Interpretacion de las metricas:

R2 = 0.6729: La IA predice correctamente el 67.3% del comportamiento economico futuro de un cliente. Para prediccion de comportamiento humano, esto es excelente y realista. Si fuera 99%, significaria que el modelo esta haciendo trampa (memorizando datos).

MAE = 466 Bs: El modelo se equivoca en promedio 466 bolivianos. Si el cliente real vale Bs 4,000, el modelo predice entre Bs 3,534 y Bs 4,466. Suficientemente preciso para segmentar si alguien es VIP o cliente comun.

Por que gano la Regresion Lineal sobre XGBoost?

Este resultado ensenja algo importante sobre el negocio: el comportamiento de compra es esencialmente lineal. A mayor frecuencia y mas articulos, mas dinero, sin patrones ocultos complicados. Esto simplifica enormemente el sistema en produccion: el servidor entrega predicciones en microsegundos y usa mucho menos memoria RAM que XGBoost, con exactamente la misma calidad predictiva.

BENEFICIO DE LA COMPETENCIA: Sin el torneo, hubieramos asumido que XGBoost es siempre el mejor. El experimento demostro que la solucion mas simple es la correcta, ahorrando recursos computacionales en produccion.

SECCION 8 - Feature Importance: Que variables importan mas?

Que hace esta seccion?

Una vez elegido el mejor modelo, se calcula que tanto peso le dio la IA a cada variable para tomar sus decisiones. Este grafico responde: de todo lo que sabemos del cliente, que es lo que realmente determina su valor economico?




Figura: clv_feature_importance.png - Importancia relativa de cada variable

Interpretacion:

La barra de Frecuencia de Compra (FREQ_TOTAL) aplasta a las demas. La Cantidad de Articulos ocupa el segundo lugar. La Edad del cliente queda al final con minima relevancia.

LECCION EMPRESARIAL CRITICA: A la Inteligencia Artificial no le importa si el cliente tiene 19 o 45 anos. Lo que define matematicamente el valor de un cliente es cuantas veces vuelve a comprar y cuantos productos lleva cada vez.

Esto invalida la estrategia de segmentar campanas solo por edad. La IA dice: segmenten por COMPORTAMIENTO, no por demografia.

SECCION 9 - Segmentacion Final y Resultados de Negocio

Que hace esta seccion?

Con el modelo campeon entrenado, se clasifica a los 300,000 clientes en 3 segmentos de valor y se calculan las proyecciones de ingresos por grupo, junto con la accion de marketing recomendada para cada uno.

Resultado real del sistema sobre los 300,000 clientes:

```
=====
RESULTADOS: Caso 2 - Segmentacion Predictiva de CLV
=====

Clientes analizados : 300,000
CLV historico total : Bs 803,812,054.0
Modelo campeon      : LinearRegression | R2: 0.6729

ESTANDAR (60.0%):
  Clientes      : 179,999
  CLV Prom.     : Bs 2,641
```


Accion : Nutricion progresiva - fidelizacion gradual

VIP - Cross-Sell (20.0%):

Clientes : 60,000
CLV Total : Bs 235,192,358
CLV Prom. : Bs 3,920
Accion : Campanas premium, cross-selling, trato personalizado

RIESGO - Contener Descuentos (20.0%):

Clientes : 60,001
CLV Total : Bs 93,422,066
CLV Prom. : Bs 1,557
Accion : Bloquear cupones agresivos - evaluar retencion estrategica

Interpretacion estrategica para presentar a directivos:

Los 60,000 clientes VIP generan un CLV proyectado de Bs 235 millones. Perder a estos clientes costaria mas que cualquier campana de retencion. El sistema los identifica uno por uno para que el equipo comercial les de trato preferencial.

Los 60,001 de 'Riesgo' tienen el CLV mas bajo y son los que mas cupones y descuentos solicitan. Darles descuentos agresivos erosiona el EBITDA sin retorno real de inversion. El sistema recomienda BLOQUEAR descuentos automaticos para este segmento.

Los 179,999 Estandar son el volumen del negocio. La estrategia es nutrirlos gradualmente para moverlos al segmento VIP con el tiempo.

RESUMEN EJECUTIVO CLV:
300,000 clientes analizados | Bs 803M en valor historico capturado
Modelo: LinearRegression | R2=0.67 | MAE=466 Bs
60,000 VIPs identificados | Bs 235M en CLV proyectado
Variable clave: Frecuencia de compra (correlacion +0.82)
Leccion: Fidelizacion > Captacion de nuevos clientes