

I. Segmentacion de Portafolio (Matriz BCG)

Ficha Tecnica - Modelo KMeans Implementado

Algoritmo:	KMeans Clustering
Tipo de aprendizaje:	No Supervisado (Clustering)
Tipo de datos (fuente):	Snowflake Data Warehouse (GOLD.FACT_VENTAS_DETALLE)
Variable objetivo:	Ninguna predefinida (Genera la variable Cuadrante_BCG)
Variables de entrada:	Volumen%, Margen%, Share Ganancia%, Ticket Promedio
Tamano de datos:	Pequeno (Nivel de portafolio de productos activos)
Preprocesamiento:	Estandarizacion Z-Score (StandardScaler)
Ingenieria de features:	Agregaciones SQL desde dbt (Ganancia neta y Volumen)
Parametros del modelo:	n_clusters=4 (por los 4 cuadrantes BCG), n_init=10
Hiperparametros:	random_state=42 para reproducibilidad
Division de datos:	100% entrenamiento (Aplica a todo el portafolio)
Tipo de particion:	No aplica
Validacion del modelo:	Metricas internas de densidad y separacion
Metrica de validacion:	Silhouette Score, Calinski-Harabasz Score
Entrenamiento:	Sobre todo el catalogo activo sin aleatorizacion
Prediccion:	Asignacion al cluster correspondiente (Estrella, Vaca, etc.)
Metricas evaluacion:	Silhouette Score = 0.445 (Ganador frente a GMM)
Interpretabilidad:	Muy Alta (Clusters corresponden a reglas visuales)
Control sobreajuste:	Fijacion de k=4 limite de clusters
Hardware requerido:	CPU (No requiere GPU)
Tiempo entrenamiento:	Corto (Segundos)
Tipo de problema:	Agrupamiento (Clustering)
Salida del modelo:	ID de Cluster mapeado a etiqueta BCG (Ej: Vaca Lechera)
Visualizacion:	Scatter Plot 2D (Margen vs Volumen Participacion)
Aplicacion practica:	Estrategia comercial y control de precios

Criterios de Evaluacion de Negocio

Mejora en decisiones clave:	Saber de que productos depende la rentabilidad real de la empresa (Ej. Identifico Vacas Lecheras).
Retorno economico (ROI):	Alto. Evita inversiones en productos 'Perro' y fomenta cross-selling en 'Interrogantes'.
Que tan preciso es:	Altamente preciso: refleja el 100% de la ganancia historica transaccional facturada.
Reduccion de errores / perdidas:	Previene rupturas de inventario en productos clave (Regla Pareto detectada).
Velocidad de respuesta:	Inmediata al cargar el dashboard web.
Automatizacion de procesos:	Elimina el trabajo manual de segmentar productos mes a mes en Excel.

Facilidad para entender:

Muy facil. Se traduce en la clasica matriz de cuadrantes con nombres descriptivos.

Uso real por el equipo:

Directorio y marketing lo utilizan para asignar presupuesto mensual por categoria.

2. Prediccion del valor del Cliente (CLV)

Ficha Tecnica - Modelo Linear Regression Implementado

Algoritmo:	Regresion Lineal Multiple (Ganador)
Tipo de aprendizaje:	Supervisado (Regresion)
Tipo de datos (fuente):	Snowflake (OBT_CUSTOMER_LIFETIME_VALUE)
Variable objetivo:	TARGET_CLV_HISTORICO (Valor monetario futuro)
Variables de entrada:	Frecuencia total, Cantidad articulos, Antigüedad dias
Tamano de datos:	Grande (~300,000 registros historicos de clientes)
Preprocesamiento:	Estandarizacion Z-Score (StandardScaler)
Ingenieria de features:	Agregacion historica RFM por cliente desde facturacion
Parametros del modelo:	fit_intercept=True
Hiperparametros:	Ninguno (Por naturaleza del modelo lineal)
Division de datos:	80% entrenamiento / 20% prueba
Tipo de particion:	Aleatoria (Random Split)
Validacion del modelo:	Hold-out test (Sobre el 20% no visto)
Metrica de validacion:	Coeficiente de Determinacion (R2)
Entrenamiento:	Sobre datos consolidados de clientes
Prediccion:	Valor economico esperado (Bs) por cliente a futuro
Metricas evaluacion:	R2 = 0.6729, MAE = 466 Bs
Interpretabilidad:	Muy Alta (Coeficientes indican aporte exacto de cada feature)
Control sobreajuste:	Modelo lineal basico rara vez sufre de sobreajuste complejo
Hardware requerido:	CPU (Ligero, optimo para despliegues)
Tiempo entrenamiento:	Corto (Minutos)
Tipo de problema:	Regresion de Series Historicas / Cross-sectional
Salida del modelo:	Valor continuo numerico (Bolivianos)
Visualizacion:	Feature Importance, PCA Tribus, Histograma
Aplicacion practica:	Segmentacion VIP, Estandar y en Riesgo

Criterios de Evaluacion de Negocio

Mejora en decisiones clave:

Sustituye la intuicion por un valor economico predecible. Indica quien merece un descuento especial.

Retorno economico (ROI):

Muy Alto. Identifica clientes VIP que aportan millones en proyeccion.

Que tan preciso es:

67.3% de precision predictiva (R2), extraordinariamente bueno para ciencias del comportamiento.

Reduccion de errores / perdidas:

Evita gastar margen dando cupones del 50% a clientes leales que igual compran.

Velocidad de respuesta:

Microsegundos por cliente desde la API MLflow.

Automatizacion de procesos:

Asignacion automatica de etiquetas VIP a nuevos usuarios.

Facilidad para entender:

Un valor en Bolivianos es el indicador de negocio mas directo y facil de asimilar.

Uso real por el equipo:

Operaciones lo integra para priorizar despachos y marketing para retargeting.

3. Prediccion de Fuga de Clientes (Churn)

Ficha Tecnica - Modelo GradientBoosting / XGBoost

Algoritmo:	Gradient Boosting Classifier (Ensamble de arboles)
Tipo de aprendizaje:	Supervisado (Clasificacion Binaria)
Tipo de datos (fuente):	Snowflake (OBT_CHURN_PREDICTION)
Variable objetivo:	TARGET_ES_CHURN (1 = Fuga inminente, 0 = Activo)
Variables de entrada:	Rango Edad, Frecuencia, Gasto, Ticket, Intensidad
Tamano de datos:	Grande (Mismo dataset base de clientes)
Preprocesamiento:	StandardScaler (Num) + OneHotEncoder (Cat)
Ingenieria de features:	Features derivados: Engagement e Intensidad de compra
Parametros del modelo:	n_estimators=150, max_depth=5, learning_rate=0.05
Hiperparametros:	Manejo de desbalance: class_weight='balanced'
Division de datos:	80% entrenamiento / 20% prueba
Tipo de particion:	Estratificada (StratifiedKFold) para mantener % de churn
Validacion del modelo:	Evaluacion contra Test Hold-out
Metrica de validacion:	Recall sobre la clase Churn y AUC-ROC
Entrenamiento:	Sobre OBT balanceando clases artificialmente
Prediccion:	Probabilidad (0% a 100%) de que un cliente abandone
Metricas evaluacion:	Recall-Churn maximizado para no perder fugas potenciales
Interpretabilidad:	Media (Se usa Feature Importance de los arboles)
Control sobreajuste:	max_depth restringido a 5 y learning rate bajo
Hardware requerido:	CPU multi-nucleo
Tiempo entrenamiento:	Moderado (Debido al ensamble y balanceo de datos)
Tipo de problema:	Clasificacion de Clientes
Salida del modelo:	Probabilidad de Fuga y Etiqueta de Riesgo (Si/No)
Visualizacion:	Curva ROC, Matriz de Confusion, Feature Importance
Aplicacion practica:	Campanas de retencion proactiva

Criterios de Evaluacion de Negocio

Mejora en decisiones clave:	Convierte una reaccion ('El cliente se fue') en prevencion proactiva ('Tal vez se vaya pronto').
Retorno economico (ROI):	Impacto directo a utilidades: Retener un cliente cuesta 5 veces menos que adquirir uno nuevo.
Que tan preciso es:	Optimizado via metrica Recall para asegurar detectar a la mayoría de posibles desertores reales.
Reduccion de errores / perdidas:	Evita gastar contactando a clientes seguros que no tienen intencion de irse de la compania.
Velocidad de respuesta:	Calculado de forma periodica e inyectado al CRM para disponibilidad inmediata.
Automatizacion de procesos:	Trigger automatico para el CRM: enviar correo promocional especial si prob_churn > 70%.

Facilidad para entender:

Se muestra directamente como un 'Riesgo de Fuga' estilo semaforo (Verde, Amarillo, Rojo).

Uso real por el equipo:

El equipo de Call Center lo usa como lista diaria de prioridades para llamadas de 'Mimos'.