

Análisis de Módulos Econométricos: Monitor de Eficiencia y Optimizador de Precio

Documentación técnica y evaluación de valor empresarial — Sistema HGC

Arquitectura del Sistema HGC

2026-04-23

Contenido

1. Módulo 1: Monitor de Eficiencia Operativa (SFA)	2
1.1. Descripción del Módulo	2
1.2. Fundamento Econométrico	2
1.2.1. Función de Producción Cobb-Douglas	2
1.2.2. Análisis de Frontera Estocástica (SFA)	2
1.3. Ficha Técnica del Modelo	3
1.4. Variables del Modelo	3
1.5. Métricas de Salida y su Interpretación de Negocio	3
1.5.1. Reglas Prescriptivas por Rango de Eficiencia	4
1.6. Niveles de Analítica	4
1.7. Evaluación de Impacto Empresarial	4
2. Módulo 2: Optimizador de Margen — Elasticidad de Precio	6
2.1. Descripción del Módulo	6
2.2. Fundamento Econométrico	6
2.3. Ficha Técnica del Modelo	6
2.4. Variables del Modelo	6
2.5. Proceso de Generación de Resultados	7
2.6. Niveles de Analítica	7
2.7. Evaluación de Impacto Empresarial	7

1. Módulo 1: Monitor de Eficiencia Operativa (SFA)

Ruta en el sistema: /system/econometrics/efficiency-monitor

1.1. Descripción del Módulo

El Monitor de Eficiencia Operativa aplica el marco del Análisis de Frontera Estocástica (SFA — Stochastic Frontier Analysis) para evaluar el rendimiento real de cada sucursal HGC en relación con el nivel máximo teórico de ventas alcanzable dados sus insumos operativos. A diferencia de los rankings de ventas brutas convencionales, este módulo controla el desempeño de cada unidad por sus costos operativos y volumen de transacciones, separando matemáticamente la ineficiencia técnica gestionable (u_i) del ruido estadístico aleatorio (v_i) inherente al entorno. El resultado es un **Score de Eficiencia** porcentual por sucursal y una **Brecha de Ingresos** cuantificada en Bolivianos — el monto de ventas no capturado por operar por debajo de la frontera óptima.

1.2. Fundamento Econométrico

1.2.1. Función de Producción Cobb-Douglas

El módulo adopta la forma funcional Cobb-Douglas para modelar la relación entre los insumos operativos y el output de ventas de cada sucursal:

$$Y = A \cdot L^\alpha \cdot K^\beta$$

Donde:

- Y : Ventas totales netas (output).
- L : Insumo de trabajo, representado por el costo laboral o dotación de personal.
- K : Insumo de capital, comprendido por costos operativos fijos e inventario.
- A : Factor de Productividad Total (PTF) — eficiencia intrínseca de la sucursal.
- α, β : Elasticidades parciales del producto respecto al trabajo y al capital.

Para su estimación lineal, la ecuación se transforma logarítmicamente:

$$\ln(Y) = \ln(A) + \alpha \ln(L) + \beta \ln(K) + \epsilon$$

1.2.2. Análisis de Frontera Estocástica (SFA)

El SFA supera al modelo promedio al estimar la **frontera de máxima eficiencia** — el nivel de ventas que lograría una sucursal si operara sin ineficiencias técnicas. La desviación de un punto de observación respecto a esta frontera se descompone en:

1. v_i : Ruido estadístico aleatorio — factores exógenos no controlables (estacionalidad atípica, eventos externos).
2. u_i : Ineficiencia técnica — factores controlables por la gestión local (merma excesiva, subutilización de personal, desabasto).

$$Y_i = f(X_i; \beta) \cdot \exp(v_i - u_i)$$

La implementación utiliza **Regresión Cuantílica Múltiple en el cuantil 90** ($q = 0.90$), estimando así la frontera de “mejor práctica” observada dentro de la propia cadena HGC:

```
formula = 'LOG_Y ~ LOG_X_COSTO + LOG_X_VOLUMEN'
model = smf.quantreg(formula, df).fit(q=0.90)
```

1.3. Ficha Técnica del Modelo

Característica	Detalle
Algoritmo	Regresión Cuantílica Múltiple ($q = 0.90$) — librería <code>statsmodels.formula.api</code>
Tipo de problema	Econometría de eficiencia productiva — estimación de frontera estocástica
Fuente de datos	Snowflake GOLD — vista <code>mart_econometria_eficiencia_operativa</code> (construida por dbt)
Variable dependiente	LOG_Y — logaritmo de las Ventas Totales Netas en Bolivianos
Variables independientes	LOG_X_COSTO (ln de costos) y LOG_X_VOLUMEN (ln de volumen de transacciones)
Salida clave 1	V_FRONTIER = $e^{\text{predicción del modelo}}$ — ventas teóricas máximas en Bs
Salida clave 2	SCORE_EFICIENCIA = $(V_{\text{real}}/V_{\text{frontier}}) \times 100$, recortado a 100 %
Salida clave 3	BRECHA_INGRESOS = $(V_{\text{frontier}} - V_{\text{real}})$, acotado a valores no negativos
Métrica de ajuste	Pseudo- R^2 (<code>model.prsquared</code>); valores > 0.70 confirman robustez del ajuste
Persistencia	<code>efficiency_results.json</code> en el backend — leído por el controlador Node.js en <100 ms

1.4. Variables del Modelo

Variable	Tipo	Fuente (dbt)	Descripción
LOG_Y	Dependiente	<code>mart_econometria_eficiencia_operativa</code>	Logaritmo natural de las ventas netas (Bs)
LOG_X_COSTO	Independiente	<code>int_ventas_precios_diarios</code>	Logaritmo del costo operativo total + costo de mercadería
LOG_X_VOLUMEN	Independiente	<code>fact_ventas_detalle</code>	Logaritmo del volumen de transacciones — proxy de esfuerzo laboral
ID_SUCURSAL_SK	Dimensión	<code>dim_sucursal</code>	Identificador de la unidad analizada

1.5. Métricas de Salida y su Interpretación de Negocio

Métrica	Definición	Interpretación
V_FRONTIER	Ventas teóricas máximas (Bs)	Lo que la sucursal <i>debería</i> vender si operara al 100 % de su potencial técnico
SCORE_EFICIENCIA	% de ventas reales sobre la frontera	Una sucursal con 63 % está aprovechando solo el 63 % de su capacidad dadas sus inversiones actuales

Métrica	Definición	Interpretación
BRECHA_INGRESOS	Bs perdidos por ineficiencia	Dinero mensual no capturado que representa el ROI potencial directo de una intervención de mejora

1.5.1. Reglas Prescriptivas por Rango de Eficiencia

Rango	Interpretación	Recomendación Emitida por el Sistema
95 %	Operación sobre la frontera	Benchmark. Analizar prácticas para replicar en otras unidades.
80 %–94 %	Rendimiento estándar	Mantener operación; optimizar gestión de horarios en períodos de baja demanda.
65 %–79 %	Ineficiencia moderada	Auditar procesos de merma y ejecutar capacitación del personal operativo.
< 65 %	Ineficiencia crítica	Intervención gerencial prioritaria: reducir costos fijos o implementar campaña de activación local.

1.6. Niveles de Analítica

Nivel	Estado	Implementación
Descriptivo		Ventas reales, costos e indicadores operativos históricos por sucursal desde Snowflake GOLD
Diagnóstico		Separación matemática de ineficiencia técnica (u_i) respecto al ruido estadístico (v_i); Score de Eficiencia y Brecha de Ingresos por unidad
Predictivo		Cálculo de V_FRONTIER — ventas máximas teóricas bajo los insumos actuales — mediante regresión cuantílica $q = 0.90$
Prescriptivo		Generación automática de recomendaciones de intervención categorizadas por rango de eficiencia

1.7. Evaluación de Impacto Empresarial

Criterio	Justificación
Mejora en decisiones clave	Permite a la Gerencia de Operaciones fundamentar decisiones de intervención en ineficiencia técnica cuantificada, no en comparaciones de ventas brutas que ignoran el nivel de inversión en costos e insumos de cada unidad.
Retorno económico (ROI)	La BRECHA_INGRESOS representa el retorno potencial directo de cada intervención. Si la cadena registra Bs 500,000 de brecha mensual consolidada, ese monto justifica económicamente el costo de operación del sistema de inteligencia.
Qué tan preciso es	El Pseudo- $R^2 > 0.70$ valida que las variables de costo y volumen explican la mayor parte de la varianza en los ingresos, descartando que los resultados respondan a correlaciones espurias.
Reducción de errores / pérdidas	Previene el error de cierre de sucursales con bajas ventas brutas que en realidad operan con buena eficiencia técnica dada su escala de costos, y detecta unidades con altas ventas pero ineficiencia oculta en su estructura de costos.
Velocidad de respuesta	El pipeline batch actualiza el modelo periódicamente. El controlador Node.js (<code>econometrics.controller.js</code>) sirve el JSON cacheado en menos de 100 ms, dibujando el scatter de eficiencia en el frontend sin latencia perceptible.
Automatización de procesos	Las transformaciones logarítmicas de costos y volumen se autogeneran en la capa dbt y alimentan el script Python sin intervención analítica manual, eliminando el ciclo de auditoría operativa convencional.
Facilidad para entender el resultado	La visualización de semáforo (Verde/Amarillo/Rojo) sobre el scatter plot es autointerpretable. La columna “Brecha (Bs)” en el ranking convierte la matemática de la frontera estocástica en un dato financiero directo para el directivo.
Uso real por el equipo	Es el panel de referencia de los Supervisores Regionales para la asignación de metas trimestrales de reducción de costos operativos y para la evaluación cuantitativa del desempeño de los administradores locales.

2. Módulo 2: Optimizador de Margen — Elasticidad de Precio

Ruta en el sistema: `/system/econometrics/price-optimizer`

2.1. Descripción del Módulo

El Optimizador de Margen es un módulo econométrico que estima la sensibilidad de la demanda frente a variaciones de precio para cada producto (SKU) del catálogo HGC. Mediante un modelo de Regresión Log-Log ajustado por Mínimos Cuadrados Ordinarios (OLS), el sistema calcula el coeficiente de elasticidad-precio de cada SKU, determinando con precisión cuánto varía el volumen de ventas ante cambios porcentuales en el precio unitario. La interfaz expone un simulador financiero interactivo donde el equipo comercial ajusta precios y observa en tiempo real el impacto proyectado en demanda y margen de contribución.

2.2. Fundamento Econométrico

El modelo adopta la especificación Log-Log linealizada, que asume elasticidad constante en el rango histórico de precios observados:

$$\ln(Q) = \beta_0 + \beta_1 \cdot \ln(P) + \epsilon$$

El coeficiente β_1 es directamente la **elasticidad-precio de la demanda**: una variación del 1 % en el precio produce una variación de β_1 % en la cantidad demandada. Un valor de $\beta_1 = -1.5$ indica que el producto es elástico — los clientes son sensibles al precio. Un valor de $\beta_1 = -0.3$ indica que el producto es inelástico — la demanda es poco sensible a variaciones de precio, habilitando incrementos sin pérdida significativa de volumen.

2.3. Ficha Técnica del Modelo

Característica	Detalle
Algoritmo	Regresión Log-Log por OLS — librería <code>statsmodels.api</code>
Tipo de aprendizaje	Supervisado — regresión lineal en escala logarítmica
Fuente de datos	Snowflake GOLD — vista <code>MART_ECONOMETRIA_ELASTICIDAD_BASE</code>
Variable objetivo (Y)	<code>LOG_Q_NORM</code> — logaritmo natural de la cantidad vendida normalizada
Variable de entrada (X)	<code>LOG_P</code> — logaritmo natural del precio unitario
Granularidad	Un modelo OLS independiente por cada <code>ID_PRODUCTO_SK</code>
Filtro de calidad	Mínimo 4 registros y al menos 2 precios distintos por producto
Métricas registradas	Elasticidad (β_1), Intercepto (β_0), R^2 — en MLflow experimento <code>HGC_Price_Elasticity</code>
Persistencia	<code>elasticity_coefficients.json</code> (backend local <10 ms) + tabla <code>RESULTADOS_ELASTICIDAD</code> en Snowflake

2.4. Variables del Modelo

Variable	Fuente	Descripción
LOG_P	MART_ECONOMETRIA_ELASTICIDAD_BASE	Logaritmo natural del precio de venta histórico registrado en POS
LOG_Q_NORM	MART_ECONOMETRIA_ELASTICIDAD_BASE	Logaritmo natural de la cantidad vendida normalizada por sucursal y período
PRECIO	dbt → Snowflake	Precio histórico en Bs para el scatter plot de dispersión
CANTIDAD	dbt → Snowflake	Unidades vendidas reales para los agregados históricos
ID_PRODUCTO_SK	dim_producto	Identificador único del SKU — determina el alcance del entrenamiento

2.5. Proceso de Generación de Resultados

Paso 1 — Extracción: `train.py` extrae la vista Gold MART_ECONOMETRIA_ELASTICIDAD_BASE desde Snowflake, construida por dbt a partir de `fact_ventas_detalle` y `dim_producto`, con transformaciones logarítmicas pre-calculadas.

Paso 2 — Entrenamiento por SKU: Para cada producto, se ajusta un modelo OLS con $X = \ln(\text{Precio})$ e $Y = \ln(\text{Cantidad normalizada})$, obteniendo β_1 como coeficiente de elasticidad.

Paso 3 — Persistencia dual: Los coeficientes se almacenan en Snowflake y en `elasticity_coefficients.json` local, servidos por el backend en <10 ms.

Paso 4 — Simulación frontend: Al modificar el precio, el sistema evalúa:

$$Q_{\text{nueva}} = e^{\beta_0 + \beta_1 \cdot \ln(P_{\text{nuevo}})}$$

Y calcula: $\Delta \text{Ingreso} = (Q_{\text{nueva}} \times P_{\text{nuevo}}) - (Q_{\text{actual}} \times P_{\text{actual}})$

2.6. Niveles de Analítica

Nivel	Estado	Implementación
Descriptivo		Scatter plot histórico real de precio vs. cantidad por producto y sucursal
Diagnóstico		Clasifica cada SKU como Elástico ($ \beta_1 > 1$) o Inelástico ($ \beta_1 < 1$) con su R^2 publicado
Predictivo		La función Log-Log predice la cantidad esperada ante cualquier precio simulado
Prescriptivo		El simulador señala el precio que maximiza el ingreso total y advierte cuándo una rebaja destruye margen bruto

2.7. Evaluación de Impacto Empresarial

Criterio	Justificación
Mejora en decisiones clave	Sustituye los ajustes de precio indexados a inflación general por coeficientes de elasticidad individuales por SKU, permitiendo al equipo comercial actuar con certeza sobre qué productos soportan incrementos sin erosión de volumen.
Retorno económico (ROI)	Incrementos de precio aplicados exclusivamente en SKUs con $ \beta_1 < 0.5$ capturan margen adicional sin requerir unidades extra de inventario ni esfuerzo operacional adicional.
Qué tan preciso es	El R^2 de cada modelo está publicado en el frontend. Solo se exponen SKUs con poder explicativo validado. MLflow mantiene el registro histórico de cada corrida para auditoría y comparación de versiones.
Reducción de errores / pérdidas	Previene el incremento de precio en productos elásticos que podría generar caídas de volumen del 20 %–30 % en pocas semanas, un error costoso en categorías de alta rotación como bebidas y postres.
Velocidad de respuesta	El JSON local se sirve en menos de 10 ms. La evaluación de la función exponencial se ejecuta en memoria del navegador (React), haciendo la simulación completamente instantánea para el usuario.
Automatización de procesos	El recálculo de elasticidades para toda la cartera de productos se ejecuta automáticamente con cada corrida de <code>train.py</code> , alimentada por el flujo continuo de datos desde dbt sin intervención manual.
Facilidad para entender el resultado	La interfaz traduce el modelo matemático a lenguaje financiero directo: variación de unidades esperada, ingreso adicional proyectado y diferencia de margen en Bolivianos, sin exponer coeficientes estadísticos al usuario de negocio.
Uso real por el equipo	Revisión obligatoria de la Gerencia de Marketing y Pricing antes de cada actualización trimestral de menú y previo al lanzamiento de campañas de combos con nuevo precio ancla.