

Análisis de Módulos: CLV, Canibalización y Predicción de Churn

Documentación técnica y evaluación de valor empresarial — Sistema HGC

Arquitectura del Sistema HGC

2026-04-25

Contenido

1. Módulo 1: Predicción de Valor de Vida del Cliente (CLV)	2
1.1. Descripción del Módulo	2
1.2. Ficha Técnica del Modelo	2
1.3. Variables del Modelo	2
1.4. Proceso de Obtención de Resultados	3
1.5. Niveles de Analítica	3
1.6. Evaluación de Impacto Empresarial	3
2. Módulo 2: Predicción de Canibalización entre Sucursales	5
2.1. Descripción del Módulo	5
2.2. Ficha Técnica del Modelo	5
2.3. Variables del Modelo	5
2.4. Niveles de Analítica	6
2.5. Evaluación de Impacto Empresarial	6
3. Módulo 3: Predicción de Fuga de Clientes (Churn)	8
3.1. Descripción del Módulo	8
3.2. Ficha Técnica del Modelo	8
3.3. Variables del Modelo	8
3.4. Niveles de Analítica	9
3.5. Evaluación de Impacto Empresarial	9

1. Módulo 1: Predicción de Valor de Vida del Cliente (CLV)

Ruta en el sistema: /system/predictions/clv

1.1. Descripción del Módulo

El módulo de Customer Lifetime Value (CLV) aplica un pipeline de regresión supervisado para estimar el valor monetario total que un cliente generará para la cadena HGC durante toda su relación comercial. A partir de cuatro variables de comportamiento histórico extraídas del data warehouse, el modelo produce un valor continuo en Bolivianos que cuantifica el potencial económico de cada cliente. Este indicador permite al equipo de Marketing y CRM priorizar esfuerzos de fidelización y asignar recursos de retención de forma proporcional al valor real de cada segmento.

1.2. Ficha Técnica del Modelo

Característica	Modelo Implementado
Algoritmo	XGBoost Regressor
Tipo de aprendizaje	Supervisado (Regresión)
Tipo de datos (fuente)	Base de datos Snowflake (OBT_CUSTOMER_LIFETIME_VALUE)
Variable objetivo	Valor Monetario Total (Bolivianos) esperado del cliente (TARGET_CLV_HISTORICO)
Variables de entrada	Rango de edad, Frecuencia de compra, Total de artículos, Antigüedad en días
Tamaño de datos requerido	Medio (requiere historial transaccional de clientes)
Preprocesamiento aplicado	Estandarización numéricas (StandardScaler), codificación de categóricas (OneHotEncoder)
Ingeniería de características	Agregaciones de comportamiento (frecuencia, gasto, antigüedad) consolidadas en dbt
División de datos	80 % entrenamiento / 20 % prueba
Tipo de partición	Aleatoria (train_test_split(random_state=42))
Métrica de validación	R^2 (Coeficiente de determinación) sobre el conjunto de prueba
Entrenamiento	Sobre historial de transacciones
Predicción	Valor económico futuro (CLV) de un cliente específico
Métricas de evaluación	R^2 , MAE (Error Absoluto Medio en Bs), RMSE (Raíz del Error Cuadrático en Bs)
Interpretabilidad	Alta (Permite analizar qué variables generan más valor al negocio)
Control de sobreajuste	Validado mediante corridas de MLflow en paralelo
Hardware requerido	CPU
Tiempo de entrenamiento	Corto (segundos a minutos)
Tipo de problema	Predicción de valor continuo (Regresión)
Salida del modelo	Valor continuo numérico en Bolivianos
Aplicación práctica	Priorización de presupuesto de retención y estrategias CRM personalizadas

1.3. Variables del Modelo

Variable en Sistema	Nombre de Negocio	Tipo	Descripción
RANGO_EDAD	Rango de Edad	Catagórica	Grupo etario al que pertenece el cliente (ej. 18-25, 26-35).
FEATURE_FREQ_TOTAL	Frecuencia de Compra	Numérica	Número total de veces que el cliente ha comprado históricamente.
FEATURE_CANTIDAD_ARTICULOS	Volumen de Artículos	Numérica	Cantidad total de productos adquiridos en todo el historial del cliente.
FEATURE_ANTIGUEDAD_DIAS	Antigüedad (Días)	Numérica	Días transcurridos desde que el cliente realizó su primera compra.

1.4. Proceso de Obtención de Resultados

Paso 1 — Extracción: Se extrae la vista `OBT_CUSTOMER_LIFETIME_VALUE` desde Snowflake. **Paso 2 — Competencia de modelos:** Se entrenan cinco algoritmos de regresión en paralelo, registrados en MLflow. **Paso 3 — Selección del campeón:** El pipeline con mayor R^2 se registra como `HGC_CLV_Model_Pro`. **Paso 4 — Ajuste por edad:** El backend Node.js aplica un multiplicador de negocio sobre la predicción, según el rango etario (ej. mayores multiplicadores en edades de mayor poder adquisitivo).

1.5. Niveles de Analítica

Nivel	Estado	Implementación
Descriptivo		Visualización del perfil histórico del cliente.
Diagnóstico		Segmentación del cliente por nivel de CLV proyectado (Alto / Medio / Bajo valor).
Predictivo		Predicción del CLV total en Bolivianos.
Prescriptivo		Asignación de presupuesto de retención basada en valor.

1.6. Evaluación de Impacto Empresarial

Criterio	¿Qué evalúa?	Impacto en el Módulo de CLV
Mejora en decisiones clave	Si el IA ayuda a tomar mejores decisiones	Permite al equipo de CRM priorizar relaciones de mayor retorno potencial, dejando de lado la segmentación básica.
Retorno económico (ROI)	Si el IA genera más plata de la que cuesta	Identifica a clientes que justifican una mayor inversión de retención (ej. Bs 12,000 proyectados) frente a clientes de bajo potencial.

Criterio	¿Qué evalúa?	Impacto en el Módulo de CLV
Qué tan preciso es	Frecuencia con que el IA acierta	El sistema selecciona el algoritmo con mejor métrica de R^2 , y el backend ajusta el resultado según la etapa de vida del cliente.
Reducción de errores / pérdidas	Cuánto se evitan problemas graves	Evita desperdiciar presupuesto de fidelización de manera uniforme, concentrándolo sólo donde habrá retorno real.
Velocidad de respuesta	Tiempo que ahorra el IA frente a método anterior	La API responde en milisegundos para evaluar cualquier perfil, reemplazando análisis RFM manuales que tardaban días.
Automatización de procesos	Qué tanto se reduce trabajo manual repetitivo	Automatiza la extracción desde Snowflake, la transformación en dbt y el preprocesamiento, eliminando tareas manuales en Excel.
Facilidad para entender el resultado	El equipo de negocio entiende por qué el IA dijo lo que dijo	La salida es un valor monetario directo (ej. Bs 3,450) y un segmento comprensible para cualquier analista.
Uso real por el equipo	La gente de verdad usa el IA en su día a día	Marketing y CRM lo utilizan continuamente para segmentar sus campañas de fidelización y justificar presupuestos.

2. Módulo 2: Predicción de Canibalización entre Sucursales

Ruta en el sistema: /system/predictions/cannibalization

2.1. Descripción del Módulo

El módulo cuantifica el riesgo de que una nueva sucursal capture demanda de otra unidad existente. Genera un índice de riesgo de canibalización (0 a 100 %) a partir de factores geográficos y demográficos, permitiendo al equipo de Expansión evaluar la viabilidad de una nueva apertura antes de cerrar un contrato.

2.2. Ficha Técnica del Modelo

Característica	Modelo Implementado
Algoritmo	XGBoost Regressor
Tipo de aprendizaje	Supervisado (Regresión)
Tipo de datos (fuente)	Base de datos Snowflake (OBT_CANNIBALIZATION_PREDICTION)
Variable objetivo	Índice de riesgo de canibalización (0 a 100 %)
Variables de entrada	Distancia geográfica, Diferencia de precios, Porcentaje de público compartido
Tamaño de datos requerido	Grande (entrenado con >100,000 registros para capturar casos extremos)
Preprocesamiento aplicado	Estandarización de variables numéricas (StandardScaler)
Parámetros del modelo	n_estimators=100, learning_rate=0.1, max_depth=6
División de datos	80 % entrenamiento / 20 % prueba
Tipo de partición	Aleatoria (train_test_split)
Métrica de validación	R^2 sobre el conjunto de prueba
Entrenamiento	Sobre simulaciones y datos históricos de aperturas previas
Predicción	Porcentaje de riesgo al abrir una nueva sucursal cerca de una existente
Métricas de evaluación	R^2 , RMSE (%), MAE (%)
Interpretabilidad	Alta (El modelo permite ver cómo la cercanía eleva la curva de riesgo)
Control de sobreajuste	Ajuste de profundidad máxima (max_depth=6)
Hardware requerido	CPU
Tiempo de entrenamiento	Corto a Medio
Tipo de problema	Predicción de riesgo (Regresión)
Salida del modelo	Porcentaje de riesgo continuo (0 a 100)
Aplicación práctica	Evaluación de viabilidad estratégica para nuevas aperturas

2.3. Variables del Modelo

Variable en Sistema	Nombre de Negocio	Tipo	Descripción
DISTANCIA_KM	Distancia entre Sucursales	Numérica	Distancia física en kilómetros. A menor distancia, mayor riesgo de competencia directa.

Variable en Sistema	Nombre de Negocio	Tipo	Descripción
DIFERENCIA_PRECIO	Diferencia de Precios	Numérica	Variación de precios entre sucursales. Si son similares, compiten; si difieren, segmentan mercado.
PUBLICO_COMPARTIDO	Público Compartido	Numérica	Porcentaje estimado del área de influencia geográfica y demográfica que se solapa.

2.4. Niveles de Analítica

Nivel	Estado	Implementación
Descriptivo		Visualización de distancias, precios y mercado compartido.
Diagnóstico		Clasificación del riesgo por categorías (Bajo / Medio / Alto / Crítico).
Predictivo		Predicción del índice porcentual exacto.
Prescriptivo		Recomendación de estrategias si el riesgo supera un umbral (ej. diferenciar el menú).

2.5. Evaluación de Impacto Empresarial

Criterio	¿Qué evalúa?	Impacto en el Módulo de Canibalización
Mejora en decisiones clave	Si el IA ayuda a tomar mejores decisiones	Otorga un indicador cuantitativo previo a firmar contratos de alquiler largos para nuevas sucursales.
Retorno económico (ROI)	Si el IA genera más plata de la que cuesta	Evitar una apertura con riesgo >70 % previene pérdidas operativas y transferencias inútiles de clientes por miles de Bolivianos.
Qué tan preciso es	Frecuencia con que el IA acierta	Es un modelo robusto que proyecta interacciones reales sin dejarse llevar por el optimismo de los equipos de expansión.
Reducción de errores / pérdidas	Cuánto se evitan problemas graves	Evita que una nueva sucursal sólo mueva ventas de un lugar a otro en lugar de atraer nuevos compradores.
Velocidad de respuesta	Tiempo que ahorra el IA frente a método anterior	Evalúa un cruce complejo de distancia, precio y mercado en segundos.

Criterio	¿Qué evalúa?	Impacto en el Módulo de Canibalización
Automatización de procesos	Qué tanto se reduce trabajo manual repetitivo	Cruza automáticamente ubicaciones y variables, sin necesitar engorrosos cálculos en Excel y mapas.
Facilidad para entender el resultado	El equipo de negocio entiende por qué el IA dijo lo que dijo	Salida directa y simple: “Riesgo: 78 %”, comprensible inmediatamente por la junta directiva.
Uso real por el equipo	La gente de verdad usa el IA en su día a día	Revisión obligatoria para cualquier análisis de viabilidad inmobiliaria en la zona urbana.

3. Módulo 3: Predicción de Fuga de Clientes (Churn)

Ruta en el sistema: /system/predictions/churn

3.1. Descripción del Módulo

El módulo anticipa qué clientes tienen alta probabilidad de abandonar la cadena (Churn) antes de que esto suceda. Usa historial de compras y recencia para clasificar a los clientes y emitir una probabilidad de abandono, permitiendo campañas de retención oportunas.

3.2. Ficha Técnica del Modelo

Característica	Modelo Implementado
Algoritmo	Gradient Boosting Classifier
Tipo de aprendizaje	Supervisado (Clasificación)
Tipo de datos (fuente)	Base de datos Snowflake (OBT_CHURN_PREDICTION)
Variable objetivo	Probabilidad de abandono inminente (0 = Retención, 1 = Fuga)
Variables de entrada	Rango de edad, Total de compras, Gasto histórico, Días sin comprar
Tamaño de datos requerido	Medio a Grande (Requiere historial de clientes activos e inactivos)
Preprocesamiento aplicado	Estandarización de variables numéricas y codificación One-Hot para el rango de edad
Ingeniería de características	Extracción de Recencia, Frecuencia y Valor desde la base transaccional
División de datos	80 % entrenamiento / 20 % prueba
Tipo de partición	Aleatoria estratificada (<code>train_test_split(random_state=42)</code>)
Métrica de validación	Exactitud (Accuracy) sobre el conjunto de prueba
Entrenamiento	Sobre historial real de clientes con marca de fuga consolidada
Predicción	Clasificación de Fuga/Retención y porcentaje de riesgo
Métricas de evaluación	Accuracy (88 %), Recall (82 %), F1-Score (85 %)
Interpretabilidad	Media (Se apoya en la visualización visual de días sin comprar)
Hardware requerido	CPU
Tiempo de entrenamiento	Medio
Tipo de problema	Clasificación Binaria
Salida del modelo	Veredicto textual y Score de riesgo (0 a 100 %)
Aplicación práctica	Alertas tempranas y campañas promocionales de retención focalizadas

3.3. Variables del Modelo

Variable en Sistema	Nombre de Negocio	Tipo	Descripción
RANGO_EDAD	Rango de Edad	Categórica	Segmento etario. Edades más jóvenes tienden a una mayor rotación.

Variable en Sistema	Nombre de Negocio	Tipo	Descripción
FEATURE_FRECUENCIA_HISTORICA	Total de Compras	Numérica	Cuántas veces ha comprado en total, como medida de lealtad histórica.
FEATURE_MONTO_GASTO_HISTORICO	Total	Numérica	Volumen de dinero inyectado al negocio en todo su ciclo de vida.
FEATURE_RECENCIA_DIAS	Días sin Comprar (Recencia)	Numérica	Tiempo transcurrido desde su última transacción. Es el principal síntoma de fuga.

3.4. Niveles de Analítica

Nivel	Estado	Implementación
Descriptivo		Histograma de churn histórico y evolución de gasto.
Diagnóstico		Radar chart identificando las dimensiones más deterioradas.
Predictivo		Gradient Boosting predice la probabilidad de fuga con un 88 % de Accuracy.
Prescriptivo		El sistema emite veredictos de alerta; las acciones automatizadas están en desarrollo.

3.5. Evaluación de Impacto Empresarial

Criterio	¿Qué evalúa?	Impacto en el Módulo de Churn
Mejora en decisiones clave	Si el IA ayuda a tomar mejores decisiones	Enfoca las estrategias de retención exclusivamente en clientes de riesgo (>70 %), ignorando promociones masivas ineficientes.
Retorno económico (ROI)	Si el IA genera más plata de la que cuesta	Invertir Bs 30 en un descuento a un cliente que históricamente gasta Bs 8,000 genera retornos sustanciales.
Qué tan preciso es	Frecuencia con que el IA acierta	Detecta exitosamente a 4 de cada 5 clientes que realmente estaban en proceso de abandono (Recall 82 %).
Reducción de errores / pérdidas	Cuánto se evitan problemas graves	Disminuye regalar dinero a clientes que igual iban a comprar, y evita perder clientes recuperables.

Criterio	¿Qué evalúa?	Impacto en el Módulo de Churn
Velocidad de respuesta	Tiempo que ahorra el IA frente a método anterior	Analiza en tiempo real miles de perfiles a través del endpoint <code>POST /api/ml/churn</code> .
Automatización de procesos	Qué tanto se reduce trabajo manual repetitivo	El modelo obtiene datos directamente preparados en dbt desde transacciones, sin manipulación de datos adicional.
Facilidad para entender el resultado	El equipo de negocio entiende por qué el IA dijo lo que dijo	La alerta estilo semáforo (“FUGA INMINENTE”) permite a un vendedor o marketer actuar de inmediato sin saber de ML.
Uso real por el equipo	La gente de verdad usa el IA en su día a día	Genera los listados semanales que guían al equipo de Fidelización en su trabajo diario.